

Modelowanie statystyczne

Autor: Wiktoria Awramik

Spis treści

1. Wprowadzenie i opis problemu badawczego.....	2
2. Opis danych i przygotowanie do analizy.....	3
3. Model Regresji Liniowej.....	6
3.1. Opis teoretyczny modelu regresji liniowej prostej.....	6
3.2. Budowa modelu regresji prostej i interpretacja wyników.....	8
3.3. Statystyczny test istotności współczynnika korelacji.....	9
3.4. Weryfikacja założeń i wykresy diagnostyczne.....	10
3.5. Wyznaczenie zbioru stosowalności modelu na podstawie przedziałów ufności i predykcji.....	15
3.6. Analiza wartości odstających i wpływowych.....	18
3.7. Krosvalidacja Modelu Regresji Prostej.....	23
3.8. Wnioski i interpretacja astronomiczna modelu prostej.....	25
4. Model Regresji Wielorakiej.....	27
4.1. Opis teoretyczny modelu regresji wielorakiej.....	27
4.2. Budowa modelu regresji wielorakiej i interpretacja wyników.....	29
4.3. Weryfikacja założeń modelu (Analiza reszt).....	31
4.4. Analiza współliniowości wskaźnikiem VIF.....	35
4.5. Analiza wykresu Residuals vs Leverage.....	36
4.6. Redukcja wymiarowości – Regresja krokowa.....	38
4.7. Diagnostyka wpływowa i odstająca.....	43
4.8. Porównanie modelu bazowego z ostatecznym modelem końcowym.....	51
4.9. Wyznaczenie zbioru stosowalności modelu wielorakiego na podstawie przedziałów ufności i predykcji.....	53
4.10. Ewaluacja hipotez i odpowiedzi na pytania badawcze.....	55
4.11. Podsumowanie i wnioski strukturalne modelu regresji wielorakiej.....	56
5. Podsumowanie Końcowe i Perspektywa Astrofizyczna.....	57

1. Wprowadzenie i opis problemu badawczego

Temat projektu

Modelowanie predykcyjne i wielowymiarowa analiza diagnostyczna fizycznej średnicy asteroid z wykorzystaniem metod regresji liniowej prostej oraz wielorakiej.

Cel analizy

Głównym celem projektu jest matematyczne zbadanie i odwzorowanie zaawansowanych zależności fizyczno-orbitalnych ciał niebieskich przemieszczających się w obrębie Układu Słonecznego. Analiza koncentruje się wokół zbudowania modeli regresyjnych, które pozwolą na precyzyjne prognozowanie i szacowanie fizycznej średnicy asteroidy na podstawie łatwiej obserwowalnych parametrów fotometrycznych (jasności, zdolności odbijania światła) oraz parametrów charakteryzujących geometrię ich orbit wokół Słońca. Ważnym elementem pracy jest przeprowadzenie pełnej diagnostyki modeli, identyfikacja anomalii i obserwacji wpływowych, a także redukcja wymiarowości zjawiska za pomocą statystycznych metod eliminacji zmiennych współliniowych.

Pytania badawcze

W celu usystematyzowania toku analitycznego, sformułowano następujące pytania badawcze:

1. Czy bazując wyłącznie na pojedynczej, kluczowej cesze fizycznej (jasności absolutnej obiektu H), jesteśmy w stanie precyzyjnie aproksymować wielkość i średnicę asteroidy?
2. W jakim stopniu rozbudowanie struktury matematycznej o dodatkowe predyktory orbitalne (takie jak mimośród, inklinacja czy półos wielka orbity) redukuje błąd standardowy reszt i podnosi zdolności wyjaśniające modelu?
3. Które parametry opisujące mechanikę nieba wykazują najsilniejsze zjawisko współliniowości i jak usunięcie tych zmiennych za pomocą analizy wskaźnika VIF wpływa na stabilność i interpretowalność ostatecznego modelu wielorakiego?

Znaczenie analizowanego problemu

Weryfikacja powyższych pytań badawczych posiada fundamentalne znaczenie we współczesnej astrofizyce oraz inżynierii kosmicznej. Bezpośredni pomiar fizycznych rozmiarów (średnicy) odległych ciał niebieskich za pomocą aparatury optycznej jest procesem niezwykle skomplikowanym, kosztownym i obciążonym dużym błędem. Obserwacje teleskopowe najczęściej dostarczają nam danych pośrednich – mierzona jest jasność oraz rejestrowana jest pozycja obiektu w czasie, z której oblicza się

elementy orbitalne. Wykazanie silnych, stabilnych zależności regresyjnych pozwala na szybkie oszacowanie gabarytów nowo odkrytych obiektów. Wiedza ta jest krytyczna z perspektywy bezpieczeństwa planetarnego (identyfikacja i ocena potencjału destrukcyjnego obiektów zagrażających Ziemi - ang. Potentially Hazardous Asteroids) oraz w kontekście dynamicznie rozwijającego się sektora górnictwa kosmicznego.

2. Opis danych i przygotowanie do analizy

Źródło danych

Analizę statystyczną oparto na danych pozyskanych bezpośrednio ze źródła – systemu **Small-Body Database (SBDB) Query**, utrzymywanego przez Jet Propulsion Laboratory (JPL), będącego oficjalnym centrum badawczym Narodowej Agencji Aeronautyki i Przestrzeni Kosmicznej (NASA). Narzędzie to agreguje na bieżąco zweryfikowane pomiary fizyczne oraz wyznaczone elementy orbitalne dla wszystkich znanych ciał Układu Słonecznego. Dostęp do bazy danych uzyskano za pośrednictwem oficjalnego portalu:

https://ssd.jpl.nasa.gov/tools/sbdb_query.html.

Klasyfikacja i opis zmiennych

Do celów modelowania wyselekcjonowano wyłącznie zmienne o charakterze ilościowym ciągłym, co stanowi warunek konieczny do poprawnego zastosowania klasycznej metody najmniejszych kwadratów (KMNK) w analizie regresji.

Nazwa zmiennej	Typ zmiennej	Rola w modelu	Opis, jednostka i znaczenie astronomiczne
diameter	Ilościowa ciągła	Zmienna objaśniana Y	Fizyczna średnica asteroidy wyrażona w kilometrach (km). Stanowi cel predykcji.

H	Ilościowa ciągła	Zmienna objaśniająca X1	Jasność absolutna (magnitudo). Określa blask obiektu hipotetycznie umieszczonego 1 AU od Słońca i Ziemi. Im mniejsza wartość, tym obiekt jaśniejszy.
albedo	Ilościowa ciągła	Zmienna objaśniająca X2	Albedo geometryczne. Współczynnik z przedziału [0, 1] określający, jaką część padającego światła słonecznego odbija powierzchnia asteroidy.
e	Ilościowa ciągła	Zmienna objaśniająca X3	Mimośród (ekscentryczność) orbity. Miara określająca stopień wydłużenia orbity (odchylenia od idealnego okręgu).
a	Ilościowa ciągła	Zmienna objaśniająca X4	Półś wielka orbity wyrażona w jednostkach astronomicznych (AU). Określa średnią odległość asteroidy od Słońca.
q	Ilościowa ciągła	Zmienna objaśniająca X5	Odległość w peryhelium (AU). Punkt orbity położony najbliżej gwiazdy macierzystej.
i	Ilościowa ciągła	Zmienna objaśniająca X6	Inklinacja (nachylenie orbity). Kąt zawarty między płaszczyzną orbity asteroidy a płaszczyzną ekliptyki (wyrażony w stopniach).
node	Ilościowa ciągła	Zmienna objaśniająca X7	Długość węzła wstępującego (stopnie). Kąt na płaszczyźnie odniesienia od punktu Barana do węzła wstępującego.

peri	Ilościowa ciągła	Zmienna objaśniająca X8	Argument peryhelium (stopnie). Kąt mierzony wzdłuż orbity od węzła wstępującego do punktu najbliższego Słońcu.
M	Ilościowa ciągła	Zmienna objaśniająca X9	Anomalia średnia (stopnie). Miara pozycji asteroidy na orbicie eliptycznej, odniesiona do wybranej epoki czasowej.
Q	Ilościowa ciągła	Zmienna objaśniająca X10	Odległość w aphelium (AU). Punkt na trajektorii lotu położony najdalej od Słońca.
n	Ilościowa ciągła	Zmienna objaśniająca X11	Średni ruch dobowy (stopnie/dzień). Prędkość kątowna poruszania się obiektu po orbicie.
period (years)	Ilościowa ciągła	Zmienna objaśniająca X12	Okres orbitalny. Czas wymagany do wykonania jednego pełnego okrążenia wokół Słońca, wyrażony w latach ziemskich.
data-arc span	Ilościowa ciągła	Zmienna objaśniająca X13	Rozpiętość łuku obserwacyjnego wyrażona w dniach. Pokazuje interwał czasowy, przez jaki obiekt był śledzony przez astronomów.
# obs. used (total)	Ilościowa ciągła	Zmienna objaśniająca X14	Całkowita liczba pomiarów pozycji (obserwacji), które posłużyły do zmatematyzowania i wyznaczenia elementów orbitalnych asteroidy.

Selekcja i czyszczenie danych badawczych

Wszelkie operacje na danych zostały przeprowadzone w środowisku RStudio za pomocą skryptu *czyszczenie_danych.R*, pracującego na bezpiecznej kopii zbioru źródłowego.

Proces ten przebiegał w trzech szybkich krokach:

1. **Weryfikacja braków pomiarowych:** Wszystkie wybrane zmienne (\$1\$ zmienna objaśniana oraz 14 zmiennych objaśniających) zostały ujednolicone do typu numerycznego. Następnie za pomocą algorytmu usuwania listowego ze zbioru wyeliminowano wszystkie rekordy zawierające jakiegokolwiek braki danych (wartości NA).
2. **Filtracja fizycznych anomalii:** Ze zbioru usunięto rzadkie obiekty o gigantycznych rozmiarach (średnica > 100 km). Dzięki temu eliminujemy ryzyko, że pojedyncze anomalie fizyczne zniekształcą działanie klasycznej metody najmniejszych kwadratów w modelach regresji.
3. **Pobranie ostatecznej próby:** Z tak oczyszczonej bazy, liczącej pierwotnie blisko 140 tysięcy rekordów, wylosowano przy stałym ziarnie losowości reprezentatywną próbę wielkości $n = 10\,000$ obserwacji. Została ona zapisana do nowego pliku *asteroidy_clean.csv*.

3. Model Regresji Liniowej

3.1. Opis teoretyczny modelu regresji liniowej prostej

Klasyczny model regresji liniowej prostej służy do matematycznego opisanie oraz zbadania charakteru i siły zależności pomiędzy dwoma cechami o charakterze ilościowym ciągłym: **zmienną zależną** (zwana objaśnianą lub celem) **Y** oraz pojedynczą **zmienną niezależną** (zwaną predyktorem lub cechą) **X** .

Ogólne równanie teoretyczne modelu regresji liniowej prostej przyjmuje postać:

$$Y_i = \alpha X_i + \beta + \varepsilon_i \quad , i \in \{1, 2, \dots, n\}$$

gdzie:

Y_i – wartość zmiennej objaśnianej dla i-tej obserwacji,

X_i – wartość zmiennej objaśniającej dla i-tej obserwacji,

α – współczynnik kierunkowy struktury (waga predyktora). Informuje o tym, o ile jednostek średnio zmieni się wartość zmiennej Y, gdy wartość predyktora X wzrośnie o jedną jednostkę,

β – wyraz wolny modelu (stała regresji). Wyznacza teoretyczną wartość zmiennej Y w sytuacji, gdy predyktor X przyjmuje wartość równą 0,

ε_i – składnik losowy (błąd, reszta), reprezentujący tę część wariancji zmiennej Y, która nie została wyjaśniona działaniem czynnika strukturalnego X (wynika m.in. z błędów pomiarowych lub nieuwzględnienia innych cech).

Estymacja optymalnych parametrów strukturalnych a (estymator α) oraz b (estymator β) realizowana jest za pomocą Klasycznej Metody Najmniejszych Kwadratów (KMNK). Kryterium optymalizacji dąży do zminimalizowania sumy kwadratów różnic pomiędzy rzeczywistymi empirycznymi wartościami zmiennej objaśnianej y_i , a wartościami teoretycznymi $\hat{y}_i$ wyznaczonymi przez prostą regresji:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \rightarrow \min$$

W ramach diagnostyki i oceny dobroci dopasowania modelu wyznaczane są dwie fundamentalne metryki:

1. **Współczynnik determinacji R^2 (R-squared):** Przyjmuje wartości z przedziału [0, 1] i określa, jaka część całkowitej wariancji zmiennej objaśnianej została zamodelowana i wyjaśniona przez zmienną niezależną. Im bliższy wartości 1, tym model jest lepiej dopasowany.
2. **Błąd standardowy reszt RSE (Residual Standard Error):** Stanowi miarę odchylenia standardowego składników losowych i informuje, o ile średnio wartości empiryczne odchylają się od prostej regresji wyznaczonej przez model matematyczny.

W tym rozdziale, zgodnie z prawami astrofizyki fotometrycznej, jako zmienną objaśnianą Y przyjęto fizyczną średnicę asteroidy (diameter), natomiast jako predyktor X wyselekcjonowano jasność absolutną obiektu kosmicznego (H).

3.2. Budowa modelu regresji prostej i interpretacja wyników

```
Call:
lm(formula = diameter ~ H, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-7.851 -2.296 -0.013  1.337  74.131

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  50.72427    0.50743   99.96  <2e-16 ***
H            -2.96118    0.03292  -89.94  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.676 on 9998 degrees of freedom
Multiple R-squared:  0.4472,    Adjusted R-squared:  0.4472
F-statistic: 8089 on 1 and 9998 DF,  p-value: < 2.2e-16
```

Wykorzystując próbę badawczą ($n = 10\,000$), w środowisku RStudio za pomocą funkcji `lm()` zaimplementowano model regresji liniowej prostej, opisujący zależność fizycznej średnicy asteroidy (*diameter*) od jej jasności absolutnej (*H*). Na podstawie uzyskanych wyników, równanie strukturalne dopasowanej prostej regresji przyjmuje następującą postać matematyczną:

$$\widehat{diameter} = -2.96118 \cdot H + 50.72427$$

Interpretacja parametrów strukturalnych modelu

Współczynnik kierunkowy ($a = -2.96118$):

Wartość współczynnika kierunkowego jest ujemna, co jest w pełni uzasadnione z punktu widzenia fizyki i fotometrii astronomicznej (w skali magnitudo mniejsza wartość oznacza jaśniejszy obiekt). W ujęciu statystycznym oznacza to, że jeśli jasność absolutna asteroidy (*H*) wzrośnie o jedno magnitudo (czyli obiekt stanie się fizycznie ciemniejszy), to jego szacowana średnica spadnie średnio o około 2.96 kilometra.

Wyraz wolny ($b = 50.72427$):

Wyraz wolny określa teoretyczną średnicę asteroidy w sytuacji, gdy predyktor *H* przyjmuje wartość równą 0. Zgodnie z modelem, asteroida o jasności

absolutnej $H = 0$ posiadałaby średnicę wynoszącą 50.72 km. Warto zauważyć, że choć w wielu badaniach wyraz wolny stanowi jedynie abstrakcję matematyczną, w tym przypadku odnosi się do realnej, skrajnej granicy skali fotometrycznej (bardzo duże i jasne obiekty).

Ocena dobroci dopasowania i metryki błędu:

Współczynnik determinacji ($R^2 = 0.4472$): Uzyskana wartość Multiple R-squared wynosi 0.4472 (identyczna z Adjusted R-squared ze względu na pojedynczy predyktor). Oznacza to, że model regresji prostej oparty wyłącznie na jasności absolutnej wyjaśnia 44.72% całkowitej wariancji (zmienności) średnicy asteroid. Jest to umiarkowanie silny wynik predykcyjny. Wskazuje on, że cechy fotometryczne determinują rozmiar bryły kosmicznej w znaczącym stopniu, jednak ponad 55% zmienności pozostaje niewyjaśnione, co stanowi silny argument za późniejszą rozbudową struktury o predyktory orbitalne (regresja wieloraka).

Błąd standardowy reszt (RSE = 4.676):

Błąd standardowy składnika losowego na poziomie 4.676 km (dla 9998 stopni swobody) informuje, że empiryczne (rzeczywiste) rozmiary asteroid odchylają się od linii teoretycznej wyznaczonej przez model średnio o 4.676 kilometra.

3.3. Statystyczny test istotności współczynnika korelacji

W celu zweryfikowania, czy zaobserwowany liniowy związek pomiędzy rozmiarem asteroidy a jej jasnością nie jest dziełem przypadku, przeprowadzono formalny test istotności współczynnika korelacji liniowej Pearsona (wykorzystując metodę opartą na rozkładzie t-Studenta).

Sformułowanie hipotez statystycznych:

Hipoteza główna ($H_0: \rho = 0$): Współczynnik korelacji w populacji jest równy zero (brak istotnej zależności liniowej między zmiennymi).

Hipoteza alternatywna ($H_1: \rho \neq 0$): Współczynnik korelacji w populacji jest istotnie różny od zera (istnieje statystycznie istotna zależność liniowa).

--- TEST ISTOTNOŚCI KORELACJI ---

Statystyka t-empiryczna dla korelacji: 89.93895

Wartość krytyczna t-Studenta (alfa=0.05): 1.960201

Decyzja: Odrzucamy hipotezę H₀. Współczynnik korelacji jest ISTOTNY statystycznie.

Weryfikacja i decyzja statystyczna:

Do obliczeń wykorzystano liczbę obserwacji $n = 10\,000$ oraz wartość błędu pierwszego rodzaju na poziomie istotności $\alpha = 0.05$.

Wyznaczona na podstawie próby statystyka testowa (empiryczna) wyniosła:

$t_{emp} = 89.93895$.

Wartość krytyczna odczytana z rozkładu t-Studenta dla $n - 2 = 9998$ stopni swobody wyniosła: **$t_{kryt} = 1.960201$.**

Wniosek: Ponieważ zachodzi jednoznaczna relacja:

$$|t_{emp}| = 89.93895 > t_{kryt} = 1.960201$$

Statystyka empiryczna wpada głęboko w prawostronny obszar krytyczny.

Dodatkowo, wartość poziomu istotności dla predyktora H wynosi **p-value < 2e-16**, co jest wartością bliską zeru i drastycznie mniejszą od przyjętego progu $\alpha = 0.05$.

Decyzja: Mamy pełne podstawy statystyczne do odrzucenia hipotezy zerowej (H₀) na rzecz hipotezy alternatywnej (H₁). Zależność liniowa pomiędzy jasnością absolutną a średnicą asteroid jest statystycznie istotna i wysoce stabilna w badanej populacji.

3.4. Weryfikacja założeń i wykresy diagnostyczne

Po przeprowadzeniu estymacji parametrów strukturalnych modelu regresji prostej, dokonano weryfikacji fundamentalnych założeń Klasycznej Metody Najmniejszych Kwadratów (KMNK) dotyczących właściwości składnika losowego (reszt modelu).

Formalne testy statystyczne założeń

1. Badanie normalności rozkładu reszt (Test Kołmogorowa-Smirnowa)

- Hipotezy testowe:
 - H_0 : Reszty modelu charakteryzują się rozkładem normalnym.
 - H_1 : Rozkład reszt modelu jest istotnie różny od rozkładu normalnego.

```
--- TEST NORMALNOŚCI RESZT (Kolmogorov-Smirnov) ---  
  
Asymptotic one-sample Kolmogorov-Smirnov test  
  
data: reszty  
D = 0.18828, p-value < 2.2e-16  
alternative hypothesis: two-sided
```

- **Wynik empiryczny:** Statystyka testowa $D = 0.18828$, przy poziomie istotności $p\text{-value} < 2.2e-16$.
- **Interpretacja i decyzja:** Ponieważ uzyskana wartość p-value jest drastycznie mniejsza od przyjętego progu istotności $\alpha = 0.05$, odrzucamy hipotezę zerową (H_0) na rzecz hipotezy alternatywnej (H_1). Reszty modelu nie mają idealnego rozkładu normalnego. Warto jednak zaznaczyć, że przy bardzo dużych próbach badawczych ($n = 10000$) testy asymptotyczne wykazują skrajną nadwrażliwość na nawet minimalne odchylenia od idealnej teoretycznej krzywej Gaussa. Zgodnie z Centralnym Twierdzeniem Granicznym (CTG), przy tej liczbie obserwacji brak idealnej normalności reszt nie dyskwalifikuje modelu z punktu widzenia właściwości predykcyjnych, jednak świadczy o obecności silnych zaburzeń w danych (wartości odstających).

2. Badanie stałości wariancji reszt (Test homoskedastyczności Breuscha-Pagana)

- Hipotezy testowe:
 - H_0 : Składnik losowy jest homoskedastyczny (wariancja reszt jest stała dla wszystkich wartości teoretycznych).
 - H_1 : Składnik losowy jest heteroskedastyczny (wariancja reszt zmienia się, jest niestała).

```
--- TEST HOMOSKEDASTYCZNOŚCI RESZT (Breusch-Pagan) ---  
  
studentized Breusch-Pagan test
```

```
data: model_prosty
BP = 803.99, df = 1, p-value < 2.2e-16
```

- **Wynik empiryczny:** Statystyka testowa BP = 803.99, stopnie swobody df = 1, przy poziomie istotności p-value < 2.2e-16.
- **Interpretacja i decyzja:** Wartość p-value poniżej progu alpha = 0.05 nakazuje jednoznaczne odrzucenie hipotezy zerowej (H_0). W modelu występuje silne zjawisko heteroskedastyczności. Oznacza to, że błąd prognozy modelu nie jest jednorodny – dla określonych przedziałów jasności absolutnej (H) model myli się w sposób znacznie bardziej zróżnicowany niż dla innych. W kontekście fizyki asteroid jest to zjawisko intuicyjne: małe i ciemne obiekty (wysokie wartości H) wykazują znacznie większą zmienność geometryczną i strukturalną niż rzadkie, stabilne i potężne planetoidy.

3. Badanie autokorelacji reszt (Test Boxa-Pierce'a)

- Hipotezy testowe:
 - H_0 : W składniku losowym nie występuje autokorelacja (reszty są niezależne).
 - H_1 : W składniku losowym występuje autokorelacja.

```
--- TEST AUTOKORELACJI RESZT (Box-Pierce) ---
```

```
Box-Pierce test
data: reszty
X-squared = 0.75622, df = 1, p-value = 0.3845
```

```
Box-Pierce test
data: reszty
X-squared = 1.0684, df = 2, p-value = 0.5861
```


```
Box-Pierce test
data: reszty
X-squared = 5.0761, df = 3, p-value = 0.1663
```

- **Wynik empiryczny:** Dla opóźnień lag = 1, 2, 3 wartości p-value wyraźnie przekraczają próg alpha = 0.05.

- **Interpretacja i decyzja:** Brak podstaw do odrzucenia hipotezy zerowej (H_0). W modelu regresji prostej nie występuje zjawisko autokorelacji reszt. Każda obserwowana przez systemy NASA asteroida jest obiektem całkowicie autonomicznym i błąd szacowania jej wielkości nie wpływa na błąd pomiaru innego ciała niebieskiego, co w pełni spełnia fundamentalne założenie KMNK o niezależności składnika losowego.

Analiza wykresów

W celu pogłębionej oceny prawidłowości specyfikacji modelu regresji prostej oraz wizualnej weryfikacji założeń KMNK, przeanalizowano cztery klasyczne wykresy diagnostyczne.



1. Wykres Residuals vs Fitted

Wykres ten wyraźnie pokazuje największą wadę dopasowanego modelu liniowego. Układa się on w charakterystyczny kształt przypominający lustrzane odbicie logotypu „Nike”.

Interpretacja: Po lewej stronie wykresu, dla ujemnych wartości dopasowanych (od -30 do 0), punkty układają się w idealnie prostą linię o ujemnym nachyleniu. Wynika to z faktu, że dla małych i ciemnych asteroid

(wysokie wartości H) równanie regresji zaczyna generować fizycznie niemożliwe, ujemne wartości średnicy. Ponieważ rzeczywista średnica tych obiektów nie może spaść poniżej zera i jest bliska zeru, błąd modelu (reszt) staje się po prostu równy wartości dopasowanej ze znakiem minusa. To tworzy idealną, sztuczną linię diagnostyczną. Dopiero po przekroczeniu punktu 0, gdzie model zaczyna przewidywać dodatnie średnice, punkty zaczynają się stopniowo rozpraszać i gwałtownie „wyszteliwać” w górę aż do wartości 80. Pokazuje to, że model liniowy kompletnie nie radzi sobie z nieliniową (wykładniczą) zależnością rozmiaru od jasności.

2. Wykres Q-Q Residuals

Wizualizacja ta sprawdza, czy błędy modelu mają rozkład normalny (wtedy punkty leżałyby idealnie na prostej linii).

Interpretacja: Zgodnie z obserwacją, wykres jest niemal idealnie płaski i liniowy przez większość rozkładu (aż do teoretycznego kwantyla równego 2). Oznacza to, że dla zdecydowanej większości (około 95%) typowych, małych asteroid błędy są małe i przewidywalne. Jednak po przekroczeniu kwantyla 2 wykres niemal pionowo wyszteliwuje w górę, osiągając gigantyczne wartości standaryzowanych reszt (blisko 15). To ewidentny dowód na to, że rozkład reszt ma tzw. „gruby prawy ogon” (jest skrajnie asymetryczny). W populacji znajduje się grupa potężnych, jasnych asteroid, których rozmiar jest drastycznie niedoszacowany przez model liniowy.

3. Wykres Scale-Location

Służy do oceny homoskedastyczności, czyli stałości wariancji (rozrzutu) błędu.

Interpretacja: Czerwona linia tworzy tutaj bardzo łagodne, płytkie „V”, z najniższym punktem tuż po przekroczeniu wartości 0. Ogromna chmura punktów koncentruje się ciasno w przedziale wartości dopasowanych od 0 do 15. To zagęszczenie odzwierciedla strukturę naszej próby badawczej – większość z 10 000 wylosowanych obiektów to właśnie małe i średnie asteroidy, dla których błąd modelu jest relatywnie stały i skupiony. Dopiero w miarę przesuwania się w prawo, dla rzadkich i dużych obiektów, chmura zaczyna rzednąć i mocno rozchodzić się w pionie, co potwierdza heteroskedastyczność.

4. Wykres Residuals vs Leverage

Wykres ten pomaga nam wylapać obserwacje, które mają zbyt duży (toksyczny) wpływ na nachylenie prostej regresji.

Interpretacja: Główna chmura danych skupia się blisko początku układu współrzędnych, co oznacza, że większość obserwacji ma bezpieczną, niską dźwignię i małe reszty. Punkty rzeczywiście całkowicie ignorują czerwoną linię trendu (która jest sztucznie wyciągana w górę przez zaledwie kilka skrajnych anomalii) i rozpraszają się na dwa segmenty: mocniejszy, pnący się w górę (to obiekty o potężnych rozmiarach i ogromnych resztach) oraz słabszy, wysunięty mocno w prawą stronę (to obiekty o nietypowych parametrach orbitalnych/jasności, czyli o wysokiej dźwigni, ale mniejszych resztach). Co kluczowe z perspektywy diagnostycznej: żadna z tych obserwacji nie przekracza czerwonych, przerywanych linii odległości Cooka (progi 0.5 i 1.0 są całkowicie poza zasięgiem punktów). Oznacza to, że choć w zbiorze mamy ewidentne wartości odstające, żadna pojedyncza asteroida nie ma aż takiej siły, by samodzielnie „wywrócić” cały model do góry nogami.

3.5. Wyznaczenie zbioru stosowalności modelu na podstawie przedziałów ufności i predykcji

Kluczowym elementem weryfikacji modelu jest precyzyjne wyznaczenie zbioru (zakresu zmiennej objaśniającej H), dla którego prognozy matematyczne zachowują sens empiryczny oraz logiczny. W tym celu przeanalizowano zachowanie modelu poprzez pryzmat dwóch komplementarnych miar statystycznych:

- 1. Przedział ufności dla linii regresji:** Określa precyzję, z jaką szacujemy średnią wielkość asteroidy dla danej wartości jasności H .
- 2. Przedział predykcji dla nowej obserwacji:** Określa obszar, w którym z 95-procentowym prawdopodobieństwem znajdzie się rozmiar jednej, konkretnej, nowo odkrytej asteroidy o danej jasności H . Z perspektywy obrony planetarnej to właśnie przedział predykcji ma fundamentalne znaczenie aplikacyjne.

Wyniki empiryczne

```
--- MODEL PROSTY (Dla średniej wartości jasności H) ---  
Przedział ufności dla linii regresji (confidence):
```

```
          fit          lwr          upr  
1 5.281143 5.189476 5.37281
```

```
Przedział predykcji dla nowej obserwacji (prediction):  
      fit      lwr      upr  
1 5.281143 -3.886012 14.4483
```

Dla średniej wartości jasności absolutnej asteroid w badanej bazie danych, model wyznaczył teoretyczną wartość dopasowaną (średnicę) wynoszącą 5.28 km. Uzyskane przedziały prezentują się następująco:

- 95% Przedział ufności: PU = [5.19 km; 5.37 km]
- 95% Przedział predykcji: PP = [-3.89 km; 14.45 km]

Interpretacja statystyczna i uzasadnienie fizyczne

Przedział ufności dla linii regresji jest bardzo wąski (rozpiętość zaledwie 180 metrów). Oznacza to, że dysponując ogromną próbą, z ekstremalnie wysoką precyzją potrafimy wskazać, gdzie leży średnia średnica wszystkich asteroid o przeciętnym blasku.

Zupełnie inną, alarmującą informację niesie ze sobą przedział predykcji dla nowej, jednostkowej obserwacji. Dolna rampa tego przedziału wynosi -3.89km. Z punktu widzenia astrofizyki jest to całkowity absurd – fizyczna średnica ciała niebieskiego nie może przyjmować wartości ujemnych.

Wniosek końcowy – zbiór, dla którego model ma sens

Ten numeryczny wynik ostatecznie definiuje zbiór stosowalności i obnaża największą wadę modelu regresji prostej. Ponieważ model liniowy ignoruje nieliniową naturę danych oraz cechuje się wysokim błędem resztowym (RSE = 4.68 km), dolna granica pasma bezpieczeństwa dla pojedynczych prognoz wkracza w obszar liczb ujemnych nawet dla idealnie przeciętnego, średniego obiektu z bazy danych.

Model regresji prostej traci swój logiczny sens w obszarze predykcji jednostkowych, ponieważ nie potrafi zagwarantować fizycznie możliwych (dodatnich) wyników dla nowo odkrywanych ciał niebieskich o standardowej jasności. Stanowi to ostateczny, niepodważalny dowód na to, że jednowymiarowe traktowanie kosmosu jest niewystarczające i bezwzględnie wymaga wdrożenia regresji wielorakiej.

Matematyczna i fizyczna granica sensowności modelu

Z właściwości Klasycznej Metody Najmniejszych Kwadratów wynika, że przedziały ufności i predykcji przyjmują kształt hiperboli – są najwęższe (najbardziej precyzyjne) w okolicach średniej wartości predyktora, natomiast rozszerzają się gwałtownie w miarę oddalania się w kierunku wartości skrajnych.

Równanie naszego modelu ($\text{diameter} = -2.96118H + 50.72427$) wymusza liniowy spadek średnicy wraz ze wzrostem magnitudo H . Ponieważ fizyczna średnica ciała niebieskiego nie może być wartością ujemną ani równą zero ($\text{diameter} > 0$), zbiór sensowności modelu ograniczają dwa kryteria:

Kryterium wartości oczekiwanej (teoretycznej): Aby sama prosta regresji nie wskazywała wartości ujemnych, jasność absolutna musi spełniać warunek $H < 17.13$ magnitudo.

Kryterium dolnej granicy przedziału predykcji: Uwzględniając fakt, że rzeczywiste asteroidy odchylają się od prostej średnio o błąd standardowy $RSE = 4.676$ km, dolne ramie 95-procentowego przedziału predykcji osiąga wartość zero znacznie szybciej. Dla obiektów o jasności $H \geq 15.5$ magnitudo, dolna granica przedziału predykcji zaczyna przyjmować wartości ujemne.


Wniosek i definicja zbioru sensowności modelu prostej

Model regresji liniowej prostej posiada realny sens statystyczny i fizyczny wyłącznie dla zbioru obiektów o jasności absolutnej $H \in (0; 15.5)$ magnitudo.

Dla tego przedziału (reprezentującego obiekty duże, wysoce jasne i dobrze widoczne) model generuje stabilne prognozy o akceptowalnym matematycznie przedziale niepewności. Po przekroczeniu granicy $H = 15.5$ (małe, ciemne, ledwo dostrzegalne odłamki skalne), dolne pasmo predykcji wkracza w obszar liczb ujemnych, co jest fizycznym absurdem. Dowodzi to, że dla obiektów słabo świecących jednowymiarowy model liniowy całkowicie traci swoją użyteczność, co stanowi ostateczne uzasadnienie dla konieczności wdrożenia regresji wielorakiej.

3.6. Analiza wartości odstających i wpływowych

Wykres pudełkowy reszt modelu prostego (Boxplot)



Wykres pudełkowy przedstawia rozkład reszt empirycznych pierwotnego modelu i służy do identyfikacji obserwacji odstających.


Interpretacja: Kształt wykresu jednoznacznie wskazuje na skrajną asymetrię prawostronną błędów regresji. Samo „pudełko” reprezentujące rozstęp ćwiartkowy wraz z linią mediany jest silnie skompresowane i zlokalizowane bardzo blisko wartości 0.

Lewy wąs wykresu jest krótki i kończy się w okolicy wartości -8.

Po prawej stronie, tuż za granicą prawego wąsu, obserwujemy natomiast potężny, nieprzerwany ciąg pojedynczych punktów, który ciągnie się aż do wartości bliskich 70.

Oznacza to, że w analizowanym zbiorze występuje ogromna liczba anomalnych obiektów (wartości odstających), dla których pierwotny model liniowy generował potężne dodatnie błędy (drastycznie niedoszacowywał ich rzeczywistej średnicy).

Wykres odległości Cooka dla poszczególnych obserwacji



Wykres ten służy do identyfikacji obserwacji, które mają nieproporcjonalnie duży, potencjalnie destrukcyjny wpływ na stabilność i wartości oszacowań parametrów strukturalnych modelu.

Interpretacja: Czerwona linia przerywana wyznacza próg krytyczny obliczony według kryterium $4/n = 4/10000 = 0.0004$.

Ze względu na bardzo dużą liczebność próby, linia ta przebiega niemal na samym dole osi układu współrzędnych. Na wykresie doskonale widać pojedyncze, pionowe szare linie (tzw. igły), które gwałtownie „wysstrzelują” wysoko ponad wyznaczony próg, osiągając wartości zbliżone do 0.25.

Taki obraz dowodzi, że chociaż większość z 10 000 asteroid nie wykazuje cech wpływowych, to w zbiorze danych istnieje wyraźna, agresywna podgrupa obiektów o tak specyficznej kombinacji jasności absolutnej (H) i średnicy, że dosłownie „przyciągają” one do siebie prostą regresję, zniekształcając globalny wzorzec dla całej reszty próby.

Identyfikacja anomalii

Zastosowanie kryterium odległości Cooka ($D_i > 0.0004$) pozwoliło na matematyczne wyizolowanie 282 obserwacji wpływowych, co stanowi 2.82% całej próby badawczej.

Liczba zidentyfikowanych obserwacji wpływowych (kryterium 4/n): 282

Oto 5 najbardziej ekstremalnych anomalii w zbiorze, z przypisanym im konkretnym numerem indeksu z bazy danych oraz wartością odległości Cooka:

```
5 najwyższych wartości odległości Cooka w próbie:
      4926      6435      3148      7579      844
0.2647522 0.2646528 0.2581772 0.2522285 0.2401750
```

Usunięcie tych 282 rekordów pozwoliło na stworzenie nowego, przefiltrowanego zbioru danych (*df_no_outliers*), liczącego 9718 obserwacji.

Analiza strukturalna nowego modelu

--- PODSUMOWANIE NOWEGO MODELU PO USUNIĘCIU ANOMALII ---

Call:

```
lm(formula = diameter ~ H, data = df_no_outliers)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.8054	-1.5430	0.2446	1.0378	9.9807

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	31.69550	0.24675	128.5	<2e-16 ***
H	-1.75683	0.01597	-110.0	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.888 on 9716 degrees of freedom

Multiple R-squared: 0.5546, Adjusted R-squared: 0.5546

F-statistic: 1.21e+04 on 1 and 9716 DF, p-value: < 2.2e-16

Po odrzuceniu anomalii funkcja `lm()` wyznaczyła nowe równanie prostej regresji, które przyjmuje postać:

$$diameter = -1.75683 \cdot H + 31.69550$$

Współczynnik kierunkowy (alpha = -1.75683): Pozostał istotny statystycznie p-value < 2e-16). Informuje, że po usunięciu obserwacji wpływowych, wzrost jasności absolutnej o 1 magnitudo (czyli gdy obiekt jest fizycznie ciemniejszy) powoduje średni spadek szacowanej średnicy asteroidy o około 1.76 km.

Wyraz wolny (beta = 31.69550): Teoretyczna średnica wielkiej, hipotetycznej asteroidy o jasności H = 0 wynosi obecnie 31.70 km.

Porównanie modeli (Przed vs. Po usunięciu anomalii)

Aby w pełni ocenić sensowność i skuteczność przeprowadzonej procedury diagnostycznej, zestawiono kluczowe metryki dopasowania obu modeli:

Metryka statystyczna	Model pierwotny (Pełny zbiór)	Nowy model (Po usunięciu anomalii)	Zmiana i wniosek analityczny
Współczynnik determinacji R^2	44.72%	55.46%	Wzrost o 10.74 p.p. Oczyszczony model wyjaśnia ponad połowę wariancji średnicy asteroid, co oznacza znaczący skok jakości predykcji.
Błąd standardowy reszt (RSE)	4.676 km	1.888 km	Drastyczny spadek o ponad 59% Średni błąd, z jakim model myli się przy prognozowaniu średnicy, zmalał z 4.68 km do zaledwie 1.89 km.

Maksymalny błąd dodatni (Max Residual)	74.131 km	9.981 km	Spadek o 64.15 km. Największy błąd niedoszacowania został silnie zredukowany, co dowodzi ucięcia „grubego ogona” anomalii.
Współczynnik kierunkowy (alpha)	-2.96118	-1.75683	Nachylenie prostej uległo wyraźnemu wypłaszczeniu.
Wyraz wolny (beta)	50.72427	31.69550	Stała regresji spadła o blisko 19 kilometrów.

Wnioski z porównania

Porównanie parametrów dostarcza kluczowych wniosków na temat struktury danych i mechaniki KMNK:

1. Potwierdzenie toksycznego wpływu anomalii: Pierwotna prosta regresji była sztucznie i bardzo silnie podciągana w górę przez zaledwie 2.82% największych obiektów. To dlatego wyraz wolny wynosił aż 50.72 km, a linia gwałtownie opadała ($\alpha = -2.96$). Te kilkadziesiąt potężnych planetoid zniekształcało model dla pozostałych ponad 9 tysięcy typowych, mniejszych ciał niebieskich.

2. Polepszenie modelu: Po usunięciu obserwacji wpływowych nowa prosta regresji stała się znacznie bardziej wypłaszczona i stabilna. Model przestał być zdominowany przez skrajne wartości.

3. Skokowy wzrost dokładności: Ponad dwukrotne zmniejszenie błędu standardowego reszt (RSE z 4.68 do 1.89 km) oraz wyraźny wzrost współczynnika determinacji R^2 do poziomu 55.46% udowadniają, że eliminacja obserwacji na podstawie odległości Cooka była w pełni uzasadniona i pozwoliła na uzyskanie znacznie bardziej rzetelnego i precyzyjnego narzędzia predykcyjnego dla typowej populacji asteroid.

3.7. Krosvalidacja Modelu Regresji Prostej

Ostatnim, kluczowym etapem oceny stabilności nowego modelu regresji prostej jest przeprowadzenie walidacji krzyżowej (ang. Cross-Validation). Pozwala ona sprawdzić zdolności generalizacyjne modelu na danych, które nie brały udziału w procesie estymacji parametrów strukturalnych.

Opis teoretyczny procedury krosvalidacji

Zgodnie z wytycznymi projektu, oczyszczony z obserwacji wpływowych zbiór danych został losowo podzielony na 5 równych, zbalansowanych podzbiorów. W ramach procedury zbudowano 5 niezależnych modeli regresyjnych. Każdy z nich był trenowany na 80% danych (4 połączone podzbiory), a następnie testowany na pozostałych 20% danych (1 podzbiór odłożony).

Dla każdego z 5 modeli oraz dla obu rodzajów zbiorów (treningowych i testowych) obliczono dwie kluczowe metryki:

- Współczynnik determinacji (R^2): określający procent wyjaśnianej wariancji.
- Błąd standardowy reszt (RSE): pokazujący średnie odchylenie prognoz od wartości rzeczywistych.

Na koniec wyniki ze wszystkich 5 iteracji zostały uśrednione, co pozwala na obiektywną ocenę występowania zjawiska overfittingu.

Wyniki 5-krotnej krosvalidacji

```
--- Model 1 ---
Trening -> R^2: 0.5574 | RSE: 1.8855
Test    -> R^2: 0.543  | RSE: 1.8967

--- Model 2 ---
Trening -> R^2: 0.5514 | RSE: 1.8852
Test    -> R^2: 0.5666 | RSE: 1.8978

--- Model 3 ---
Trening -> R^2: 0.5485 | RSE: 1.8804
Test    -> R^2: 0.5757 | RSE: 1.9182

--- Model 4 ---
Trening -> R^2: 0.5629 | RSE: 1.9037
Test    -> R^2: 0.5123 | RSE: 1.8252

--- Model 5 ---
Trening -> R^2: 0.5526 | RSE: 1.882
```

```
Test      -> R^2: 0.5614 | RSE: 1.9106
=====
ŚREDNIE WYNIKI KROSWALIDACJI:

Średni R^2 (Trening): 0.5546
Średni R^2 (Test):    0.5518

Średni RSE (Trening): 1.8873
Średni RSE (Test):    1.8897
```

Analiza stabilności i ocena zjawiska przetrenowania(Overfitting)

Przetrenowanie modelu (overfitting) zachodzi wtedy, gdy model dopasowuje się do specyficznego szumu w próbie treningowej, przez co uzyskuje świetne wyniki na zbiorze uczącym, ale drastycznie traci dokładność na danych testowych.

W kontekście uzyskanych wyników krosvalidacji możemy sformułować następujące wnioski:

Ekstremalna stabilność metryk: Wartości współczynnika R^2 oraz błędu RSE pomiędzy poszczególnymi iteracjami wykazują minimalną zmienność. Nawet w najslabszej dla zbioru testowego iteracji (Model 4) współczynnik R^2 nie spada drastycznie, a towarzyszy mu proporcjonalnie niższy błąd RSE (1.8252 km), co świadczy o dobrej harmonii modelu. Pokazuje to, że losowy podział danych był idealnie zbalansowany, a struktura próby jest bardzo jednorodna po wcześniejszym usunięciu wartości wpływowych.

Brak przetrenowania: Średni współczynnik determinacji dla zbiorów testowych (55.18%) jest niemal identyczny z wynikiem uzyskanym na zbiorach treningowych (55.46%). Różnica wynosi zaledwie 0.28 punktu procentowego. Podobnie nienaganną zależność widać dla błędu standardowego reszt (RSE), którego średnia wartość dla zbioru treningowego (1.8873 km) oraz testowego (1.8897 km) różni się o zaledwie 0.0024 km (czyli około 2.4 metra).

Wniosek:

Analiza jednoznacznie dowodzi, że nie mamy do czynienia z zjawiskiem przetrenowania. Model oparty na regresji liniowej prostej posiada bardzo wysokie zdolności generalizacyjne. Wynika to bezpośrednio z niskiej złożoności matematycznej modelu (wykorzystanie tylko jednego predyktora – jasności absolutnej H), co z natury ogranicza ryzyko wystąpienia overfittingu.

Oczyszczone równanie regresji jest stabilne i gotowe do predykcji średnic dla nowych, niezależnych obserwacji astronomicznych.

3.8. Wnioski i interpretacja astronomiczna modelu prostej

Przekładając uzyskane wyniki statystyczne na język astrofizyki i mechaniki nieba, możemy sformułować wnioski, które rzucają światło na realną naturę badanych asteroid oraz ograniczenia samego modelowania liniowego.

Co tak naprawdę mówi nam równanie regresji?

W astronomii jasność absolutna (H) jest podawana w skali magnitudo, co oznacza, że im mniejsza wartość numeryczna, tym obiekt świeci jaśniej.

Uzyskany w modelu ujemny współczynnik kierunkowy ($\alpha \sim -1.76$) ma głęboki sens fizyczny. Oznacza on, że jaśniejsze obiekty są w populacji systematycznie większe. Z punktu widzenia geometrii jest to intuicyjne: większa bryła skalna ma większą powierzchnię geometryczną, a więc jest w stanie odbić więcej światła słonecznego w kierunku ziemskich teleskopów. Dzięki oczyszczonemu modelowi wiemy, że sam pomiar fotometryczny (błysk światła) pozwala nam z marginesem błędu wynoszącym zaledwie ok. 1.89 km określić fizyczny gabaryt kosmicznej skały.

Z perspektywy obrony planetarnej (szacowania siły potencjalnego zderzenia z Ziemią) lub górnictwa kosmicznego, taka wiedza uzyskana zdalnie na odległość milionów kilometrów ma fundamentalną wartość.

Dlaczego model liniowy „poległ” na skrajnościach? (Lustrzane „Nike”)

Analiza wykresów diagnostycznych (specyficzny kształt paraboli w rozkładzie reszt) obnażyła czysto fizyczną wadę zmuszania danych astronomicznych do układania się w linię prostą. W rzeczywistości powiązanie jasności ze średnicą nie jest liniowe, lecz wykładnicze (dwukrotne zwiększenie średnicy asteroidy zwiększa jej powierzchnię odbijania aż czterokrotnie).

Przez to, że KMNK próbuje wyznaczyć idealnie prostą linię tam, gdzie natura stworzyła krzywą, model zaczął generować absurdy:

- Dla obiektów bardzo ciemnych (wysokie H): Linia regresji opadła tak nisko, że zaczęła przewidywać dla asteroid ujemne średnice. W rzeczywistości małe asteroidy istnieją, ale ich średnice zbliżają się do zera, nigdy nie spadając poniżej.
- Dla obiektów skrajnie wielkich i jasnych (wartości odstające): Model liniowy drastycznie niedoszacowywał ich rozmiarów (błędy rzędu 70 km). Te gigantyczne planetoidy, będące pozostałościami z czasów formowania się Układu Słonecznego, wymykają się standardowej skali i dlatego musiały zostać usunięte jako wartości wpływowe, żeby nie fałszować obrazu dla reszty „normalnej” populacji.

Namacalnym, bezdyskusyjnym dowodem tej systemowej słabości stała się przeprowadzona analiza statystycznych pasów bezpieczeństwa dla obiektu o idealnie przeciętnej, średniej jasności w naszej próbie.

O ile 95-procentowy przedział ufności dla samej linii regresji okazał się niezwykle wąski ($PU = [5.19 \text{ km}; 5.37 \text{ km}]$), co dowodzi precyzyjnego oszacowania średniej na tak wielkiej próbie, o tyle przedział predykcji dla nowej, pojedynczej obserwacji całkowicie obnażył bezradność jednowymiarowego modelu liniowego.

Dla średniej asteroidy o prognozowanej wielkości 5.28 km, dolna granica 95-procentowego przedziału predykcji wyniosła -3.89 km ($PP = [-3.89 \text{ km}; 14.45 \text{ km}]$). W ujęciu astrofizycznym dopuszczenie ujemnej średnicy dla nowo odkrytego obiektu to całkowity absurd. Fakt, że to zjawisko występuje w samym centrum geometrycznym naszych danych (dla wartości średniej), a nie tylko na dalekich skrajnościach, dobitnie pokazuje, że wysoki błąd standardowy reszt w połączeniu z ignorowaniem albedo dosłownie rozrywa zdolności prognostyczne tego modelu.

Odpowiedź na pierwsze pytanie badawcze i krok w stronę regresji wielorakiej

Ostateczny test stabilności (kroswalidacja) udowodnił, że model jest niezwykle powtarzalny i wyjaśnia 55.18% zmienności średnicy asteroid wyłącznie na podstawie ich jasności. Sukces ten jest jednak tylko połowiczny.

Skoro jasność wyjaśnia 55%, to oznacza, że aż 45% informacji o rozmiarze asteroidy wciąż pozostaje w sferze zagadki. W świecie fizycznym dwie asteroidy o identycznej jasności H mogą mieć zupełnie inne rozmiary z dwóch głównych powodów:

- **Albedo (zdolność odbijania światła):** Asteroida pokryta lodem lub jasnymi krzemianami będzie mała, a i tak błysnie w teleskopie

bardzo jasno. Z kolei ogromna asteroida węglowa, czarna jak węgiel, odbija mało światła i wyda się nam mała.

- **Geometria orbity:** Pozycja obiektu względem Słońca i Ziemi determinuje warunki jego obserwacji.

Dlatego więc, odpowiedź na pierwsze pytanie badawcze, brzmiące:

“Czy bazując wyłącznie na pojedynczej, kluczowej cesze fizycznej (jasności absolutnej obiektu H), jesteśmy w stanie precyzyjnie aproksymować wielkość i średnicę asteroidy?”, brzmi: nie.

Podsumowanie sekcji: Model regresji prostej udowodnił, że jasność absolutna jest doskonałym, stabilnym punktem wyjścia do szacowania rozmiaru ciał niebieskich, ale traktowanie kosmosu w sposób „liniowy” i jednowymiarowy niesie ze sobą duże ryzyko błędu. Aby okiełznać brakujące 45% wariancji i uwzględnić różnice w budowie oraz trajektoriach asteroid, niezbędne jest porzucenie modelu prostej i przejście do Regresji Wielorakiej, co uczyniono w kolejnym rozdziale.

4. Model Regresji Wielorakiej

4.1. Opis teoretyczny modelu regresji wielorakiej

Model regresji liniowej wielorakiej (wielowymiarowej) stanowi bezpośrednie rozwinięcie modelu regresji prostej. Podczas gdy regresja prosta bada relację między zmienną objaśnianą a jednym predyktorem, regresja wieloraka pozwala na jednoczesne uwzględnienie wielu zmiennych niezależnych.

W kontekście badań astrofizycznych jest to podejście znacznie bardziej realistyczne. Pozwala ono odpowiedzieć na pytanie: jak na rozmiar asteroidy wpływa nie tylko jej jasność, ale również zdolność odbijania światła (albedo) oraz parametry jej trajektorii orbitalnej?

Równanie matematyczne modelu

Teoretyczne równanie strukturalne modelu regresji wielorakiej dla i-tej obserwacji przyjmuje postać:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

gdzie:

Y_i - wartość zmiennej objaśnianej (fizyczna średnica asteroidy dla i-tej obserwacji),

$X_{1i}, X_{2i}, \dots, X_{ki}$ - wartości poszczególnych k predyktorów

β_0 - wyraz wolny (stała regresji), określający teoretyczną wartość Y, gdy wszystkie predyktory są równe zero,

$\beta_1, \beta_2, \dots, \beta_k$ - częściowe współczynniki regresji liniowej,

ε_i - składnik losowy (błąd, reszta modelu) dla i-tej obserwacji.

Interpretacja współczynników β

Kluczową zaletą regresji wielorakiej jest możliwość interpretacji wpływów poszczególnych zmiennych przy warunku *ceteris paribus* (przy pozostałych czynnikach niezmiennych).

Współczynnik β informuje o tym, o ile jednostek średnio zmieni się wartość zmiennej objaśnianej (Y), jeśli dany predyktor (X_i) wzrośnie o jedną jednostkę, pod warunkiem, że wszystkie pozostałe zmienne objaśniające w modelu pozostaną na stałym, niezmiennym poziomie.

W tym badaniu pozwoli to np. sprawdzić, jak zmienia się średnica asteroidy wraz ze zmianą albedo dla obiektów, które mają dokładnie taką samą jasność absolutną H.

Estymacja i ocena dobroci dopasowania

Podobnie jak w regresji prostej, estymacja parametrów strukturalnych realizowana jest za pomocą Klasycznej Metody Najmniejszych Kwadratów

(KMNK), która minimalizuje sumę kwadratów reszt. Do oceny jakości modelu wielorakiego stosuje się jednak nieco zmodyfikowane metryki:

- **Skorygowany współczynnik determinacji (Adjusted R²):** Klasyczny R² ma tendencję do automatycznego wzrostu za każdym razem, gdy dodajemy do modelu jakiegokolwiek nowego predyktora (nawet zupełnie bezużytecznego). Skorygowany R² nakłada „karę” za stopnie swobody (liczbę zmiennych), dzięki czemu pozwala obiektywnie ocenić, czy rozbudowa modelu o parametry orbitalne realnie podnosi jego wartość poznawczą.
- **Błąd standardowy reszt (RSE):** Informuje, o ile średnio rzeczywiste średnice asteroid odchylają się od wielowymiarowej płaszczyzny regresji wyznaczonej przez algorytm.

Główne założenia modelu wielorakiego

Aby estymatory KMNK były najlepszymi, nieobciążonymi estymatorami liniowymi, oprócz normalności, homoskedastyczności i braku autokorelacji reszt, musi zostać spełnione jedno dodatkowe, fundamentalne założenie:

- **Brak współliniowości predyktorów:** Zmienne objaśniające nie mogą być ze sobą silnie skorelowane liniowo. W astronomii to częsty problem – np. okres orbitalny asteroidy jest ściśle powiązany z jej półosią wielką. Jeśli wprowadzimy do modelu dwie zmienne niosące tę samą informację, model stanie się niestabilny, a błędy standardowe współczynników drastycznie wzrosną. Do wykrywania tego zjawiska stosuje się analizę macierzy korelacji oraz wskaźnik VIF (Variance Inflation Factor).

4.2. Budowa modelu regresji wielorakiej i interpretacja wyników

Na podstawie oczyszczonej próby ($n = 10000$) zbudowano pełny model regresji liniowej wielorakiej dla zmiennej objaśnianej *diameter*. Z analizy wykluczono zmienną q (odległość w peryhelium), która wywoływała zjawisko idealnej współliniowości.

--- PODSUMOWANIE PEŁNEGO MODELU WIELORAKIEGO ---

Call:

```
lm(formula = diameter ~ . - q, data = df)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-19.910	-1.155	-0.188	0.895	65.999

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.105e+01	1.701e+00	12.380	< 2e-16	***
H	-1.965e+00	6.856e-02	-28.661	< 2e-16	***
albedo	-1.864e+01	4.175e-01	-44.633	< 2e-16	***
e	1.761e+01	1.883e+00	9.349	< 2e-16	***
a	8.163e+00	4.820e-01	16.935	< 2e-16	***
i	5.664e-02	6.303e-03	8.985	< 2e-16	***
om	5.508e-04	3.792e-04	1.452	0.1464	
w	-3.561e-04	3.748e-04	-0.950	0.3421	
ma	1.898e-04	3.642e-04	0.521	0.6023	
ad	-5.459e+00	6.580e-01	-8.296	< 2e-16	***
n	9.981e+00	1.285e+00	7.768	8.76e-15	***
per_y	3.501e-01	1.567e-01	2.233	0.0255	*
data_arc	3.151e-04	1.034e-05	30.471	< 2e-16	***
n_obs_used	3.689e-04	5.202e-05	7.093	1.40e-12	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.87 on 9986 degrees of freedom

Multiple R-squared: 0.6219, Adjusted R-squared: 0.6214

F-statistic: 1263 on 13 and 9986 DF, p-value: < 2.2e-16

Ocena globalna i dopasowanie modelu

Współczynnik determinacji (R^2): Wynosi 0.6219 (skorygowany $R^2 = 0.6214$). Oznacza to, że rozbudowanie struktury matematycznej o dodatkowe predyktory orbitalne i fotometryczne pozwoliło na wyjaśnienie aż 62.19% całkowitej wariancji wielkości asteroid.

Porównanie z regresją prostą: Wynik ten należy zestawić z wyjściowym modelem regresji prostej dla tego samego, nieoczyszczonego zbioru danych ($R^2 = 44.72\%$). Dodanie parametrów orbitalnych i fizycznych przyniosło potężny skok efektywności o 17.47 punktów procentowych. Co niezwykle imponujące, ten surowy, pełen anomalii model wieloraki (62.19%) osiąga znacznie lepsze dopasowanie niż idealnie oczyszczony z wartości wpływowych model regresji prostej (55.46%). Dowodzi to, że uwzględnienie wielowymiarowej geometrii kosmosu niesie ze sobą nieporównywalnie większą wartość poznawczą niż samo czyszczenie danych.

Błąd standardowy reszt (RSE): Spadł z poziomu 4.676 km do 3.87 km. Oznacza to, że średni błąd prognozy rozmiaru asteroidy zmniejszył się o blisko 17%.

Istotność statystyczna modelu: Statystyka F wynosi 1263, a odpowiadająca jej wartość p-value $< 2.2e^{-16}$. Model jako całość jest wysoce istotny statystycznie.

Analiza istotności i kierunku wpływu predyktorów

Aż 10 z 13 wprowadzonych predyktorów okazało się wysoce istotnych statystycznie (p-value < 0.05). Na szczególną uwagę zasługują zmienne o kluczowym znaczeniu astronomicznym:

- **albedo (beta = -18.64):** Wykazuje silny i logiczny wpływ ujemny. Albedo określa zdolność powierzchni do odbijania światła. Przy stałej jasności absolutnej H, wzrost albedo o 0.1 powoduje spadek szacowanej średnicy asteroidy o 1.86 km. Fizycznie oznacza to, że obiekt mniejszy, ale "jaśniejszy" (lepiej odbijający światło, np. pokryty lodem) generuje taki sam blask jak potężna, ale ciemna, węglowa skała.
- **H (beta = -1.965):** Ujemny wpływ jasności absolutnej uległ wzmocnieniu w porównaniu do modelu prostej (wcześniej -2.96), ponieważ część jego dotychczasowej siły wyjaśniającej przejęła nowo wprowadzona zmienna albedo.
- **Predyktory nieistotne:** Kąty opisujące orientację orbity w przestrzeni: długość węzła wstępującego (om, $p = 0.1464$), argument peryhelium (w, $p = 0.3421$) oraz anomalia średnia (ma, $p = 0.6023$) nie mają żadnego wpływu na fizyczny rozmiar bryły, co jest w pełni zgodne z prawami astrofizyki.

4.3. Weryfikacja założeń modelu (Analiza reszt)

Normalność rozkładu reszt

--- TEST NORMALNOŚCI RESZT (Kolmogorov-Smirnov) ---

Asymptotic one-sample Kolmogorov-Smirnov test


data: reszty_wielorakie

D = 0.18762, p-value < 2.2e-16
alternative hypothesis: two-sided

Wynik testu Kołmogorowa-Smirnowa:

Statystyka D = 0.18762, p-value < 2.2e-16.

Hipoteza zerowa o normalności zostaje odrzucona.



Wykres Q-Q:

Podobnie jak w regresji prostej, centralna część rozkładu układa się liniowo, natomiast prawy ogon drastycznie wystrzeliwuje w górę (ciężkie ogony), co świadczy o obecności grupy wielkich asteroid, których model liniowy nie potrafi poprawnie oszacować.

Homoskedastyczność (Stałość wariancji)

--- TEST HOMOSKEDASTYCZNOŚCI RESZT (Breusch-Pagan) ---

studentized Breusch-Pagan test



data: model_pelny

BP = 1435.3, df = 13, p-value < 2.2e-16

Wynik testu Breuscha-Pagana:

Statystyka BP = 1435.3, p-value < 2.2e-16.

Odrzucamy hipotezę o stałości wariancji. Występuje heteroskedastyczność.



Wykresy Residuals vs Fitted oraz Scale-Location wciąż zachowują paraboliczny kształt (lustrzane "Nike"), co dowodzi nieliniowej natury kosmicznych danych fotometrycznych.

Autokorelacja reszt (Sukces modelu wielorakiego)

--- TEST AUTOKORELACJI RESZT (Box-Pierce) ---

```
Box-Pierce test
data:  reszty_wielorakie
X-squared = 0.6121, df = 1, p-value = 0.434
```

```
Box-Pierce test
data:  reszty_wielorakie
X-squared = 0.78062, df = 2, p-value = 0.6768
```

```
Box-Pierce test
data:  reszty_wielorakie
X-squared = 3.2469, df = 3, p-value = 0.3551
```

Wynik testu Boxa-Pierce'a:

Dla wszystkich trzech opóźnień (lag = 1, 2, 3) wartości p-value wynoszą odpowiednio: 0.4340, 0.6768 oraz 0.3551. Ponieważ są one znacznie większe od progu $\alpha = 0.05$, brak jest podstaw do odrzucenia hipotezy zerowej.

Wniosek: W modelu nie występuje autokorelacja reszt. Błędy losowe dla poszczególnych asteroid są całkowicie niezależne, co stanowi ogromną zaletę tego modelu w porównaniu do modeli budowanych na danych czasowych czy biologicznych.

Fizyczna rzeczywistość

Statystyczne testy diagnostyczne zgodnie ogłosiły katastrofę: normalność reszt oraz homoskedastyczność zostały bezwzględnie odrzucone. Schodząc jednak na poziom fizyki Układu Słonecznego, wyniki te są perfekcyjnym odzwierciedleniem natury kosmosu.

1. Dlaczego rozkład reszt ma „ciężkie ogony” (Brak normalności)

Wykres Q-Q pokazuje idealną liniowość przez 90% czasu, po czym w prawym ogonie pionowo wystrzeliwuje w kosmos. Dzieje się tak, ponieważ wszechświat nie tworzy asteroid według stałego, symetrycznego rozkładu normalnego. Rozkład wielkości ciał niebieskich rządzi się prawem potęgowym, będącym efektem miliardów lat kolizji. W kosmosie krążą miliony drobnych odłamków i zaledwie garstka gigantycznych, kilkudziesięciokilometrowych potworów. Model liniowy zakłada, że błędy powinny rozkładać się symetrycznie wokół prostej. Gdy jednak w próbie 10 000 obiektów pojawia się nagle kilkanaście unikalnych, potężnych planetoid, model drastycznie zaniża ich rozmiar, generując gigantyczne reszty (odchylenia) rzędu 60 km, co bezpowrotnie niszczy teoretyczną normalność.

2. Skąd się wzięło lustrzane „Nike” (Heteroskedastyczność)

Wykresy Residuals vs Fitted oraz Scale-Location ponownie ułożyły się w nieliniową parabolę. Wynika to z faktu, że mniejsze asteroidy cechują się gigantyczną różnorodnością strukturalną – mogą być luźnymi zlepionkami gruzu, litym żelazem lub jądrami dawnych komet pokrytymi lodem. Ta kosmiczna różnorodność sprawia, że ich wariancja drastycznie puchnie dla pewnych przedziałów jasności, uniemożliwiając spełnienie założenia o stałości wariancji (homoskedastyczności).

3. Brak autokorelacji reszt

Test Boxa-Pierce'a przyniósł rzadko spotykany w tak wielkich zbiorach sukces: dla opóźnień 1, 2 i 3 wartości p-value są ogromne (od 0.35 do 0.67), co oznacza całkowity brak autokorelacji. W przeciwieństwie do danych ekonomicznych czy laboratoryjnych, gdzie kolejne pomiary mogą na siebie wpływać, każda asteroida w bazie danych NASA jest całkowicie niezależnym bytem podróżującym przez próżnię. Błąd pomiaru jednego obiektu nie niesie żadnej informacji o błędzie pomiaru drugiego, co idealnie spełnia to jedno, fundamentalne założenie KMNK.

4.4. Analiza współliniowości wskaźnikiem VIF

```
--- ANALIZA WSPÓLLINIOWOŚCI (VIF) ---
      H      albedo      e      a      i      om
w      ma      ad      n      per_y
  6.331381   1.474577  16.250073  44.959888   1.172757   1.015939
1.017038   1.007621 155.956434   4.644621  68.374170
data_arc n_obs_used
```

2.597388 5.689517

Uruchomienie algorytmu VIF ujawniło potężną, nieliniową współliniowość wewnątrz układu predyktorów:

- ***ad*** (odległość w aphelium) → VIF = 155.96
- ***per_y*** (okres orbitalny w latach) → VIF = 68.37
- ***a*** (półoś wielka) → VIF = 44.96
- ***e*** (mimośród orbity) → VIF = 16.25


Interpretacja astronomiczna

Wskaźniki te dosłownie "płoną", drastycznie przekraczając barierę wynoszącą 5. Jest to bezpośrednia konsekwencja Trzeciego Prawa Keplera* ($T^2 \propto a^3$), stąd gigantyczna współliniowość między *per_y* a *a*) oraz czystej geometrii elipsy, gdzie aphelium jest funkcją półosi i mimośrodu ($ad = a \cdot (1 + e)$). Wprowadzenie tych zmiennych naraz powoduje dublowanie informacji i sztucznie zawyża błędy standardowe współczynników, co bezwzględnie wymaga przeprowadzenia regresji krokowej w następnym etapie.

[* Trzecie Prawo Keplera określa zależność między okresem orbitalnym planety a jej średnią odległością od Słońca.

Można je zapisać wzorem: $T^2 \propto a^3$, co oznacza, że kwadrat czasu obiegu planety jest proporcjonalny do sześcianu długości półosi wielkiej jej orbity.]

4.5. Analiza wykresu Residuals vs Leverage



Wykres Residuals vs Leverage w modelu regresji wielorakiej dostarcza bardzo ciekawych informacji o strukturze próby i koryguje wyobrażenie o rozkładzie cech wpływowych.

- **Pionowa ściana - wartości przeciętne ($Leverage \approx 0$):** Wbrew intuicji, po spojrzeniu na wykres widać, że zdecydowana większość z 10 000 punktów tworzy idealnie pionową, gęstą ścianę zlokalizowaną tuż przy wartości zero na osi dźwigni. W ujęciu astronomicznym ta potężna, skompresowana chmura reprezentuje statystyczną masówkę Układu Słonecznego – klasyczne, standardowe asteroidy Pasa Głównego krążące między Marsem a Jowiszem. Mają one niemal identyczne, przeciętne półosie wielkie, niskie inklinacje i kołowe orbity. Siedzą tak ciasno w „środku ciężkości” układu predyktorów, że ich indywidualna siła dźwigni (wpływu na model) wynosi okrągłe zero.
- **Wyjątki - uciekinierzy (Ekstremalny Leverage):** Prawdziwa magia dzieje się dalej na osi X. Tylko nieliczne, pojedyncze punkty odrywają się od pionowej ściany i rozpraszają poziomo daleko w prawą stronę, osiągając gigantyczną dźwignię rzędu 0.4, a nawet bliską 0.9 dla jednej asteroidy. Są to orbitalne osobliwości: obiekty bliskie Ziemi (NEA), obiekty transneptunowe lub planetoidy Trojańskie o skrajnych, nienaturalnych dla Pasa Głównego nachyleniach i trajektoriach. Ponieważ są zupełnie samotne w przestrzeni wielowymiarowej, zyskują gigantyczną siłę dźwigni.
- **Kluczowy wniosek:** Co najważniejsze, te anomalie orbitalne o wysokiej dźwigni (w tym punkt 6927) znajdują się bardzo blisko

poziomej linii zerowej reszt (Residuals = 0). Oznacza to, że choć ich orbity są dziwaczne, model regresji wielorakiej (dzięki uwzględnieniu geometrii) potrafi idealnie i bezbłędnie wyliczyć ich fizyczną średnicę. Zagrożeniem są natomiast punkty po lewej stronie wykresu – mają zerową dźwignię (są zwykłymi obiektami z Pasa Głównego), ale ich reszty standaryzowane przekraczają wartość 15. To właśnie te gigantyczne niedoszacowania wielkości będą celem nadchodzącej regresji krokowej i filtracji odległością Cooka.

4.6. Redukcja wymiarowości – Regresja krokowa

Przebieg procedury i zbieżność algorytmów

--- PRZEBIEG ELIMINACJI WSTECZNEJ ---

Stepwise Summary						
Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Full Model	55459.423	55567.578	NA	0.62190	0.62141
1	ma	55457.695	55558.640	NA	0.62189	0.62144
2	w	55456.591	55550.326	NA	0.62186	0.62144

Final Model Output

Model Summary			
R	0.789	RMSE	3.867
R-Squared	0.622	MSE	14.957
Adj. R-Squared	0.621	Coef. Var	73.275
Pred R-Squared	0.617	AIC	55456.591
MAE	1.770	SBC	55550.326

RMSE: Root Mean Square Error

MSE: Mean Square Error

MAE: Mean Absolute Error

AIC: Akaike Information Criteria

SBC: Schwarz Bayesian Criteria

ANOVA

	Sum of Squares	DF	Mean Square	F	Sig.
Regression	245970.357	11	22360.942	1493.217	0.0000
Residual	149570.394	9988	14.975		
Total	395540.750	9999			

Parameter Estimates

model	Beta	Std. Error	Std. Beta	t	sig	lower	upper
(Intercept)	20.981	1.695		12.375	0.000	17.657	24.304
H	-1.963	0.069	-0.443	-28.647	0.000	-2.098	-1.829
albedo	-18.617	0.417	-0.333	-44.637	0.000	-19.434	-17.799
e	17.569	1.883	0.231	9.331	0.000	13.879	21.260
a	8.158	0.482	0.698	16.932	0.000	7.214	9.103
i	0.057	0.006	0.060	9.005	0.000	0.044	0.069
om	0.001	0.000	0.010	1.573	0.116	0.000	0.001
ad	-5.445	0.658	-0.636	-8.278	0.000	-6.735	-4.156
n	9.973	1.285	0.103	7.763	0.000	7.455	12.491
per_y	0.347	0.157	0.113	2.213	0.027	0.040	0.654
data_arc	0.000	0.000	0.303	30.550	0.000	0.000	0.000
n_obs_used	0.000	0.000	0.104	7.067	0.000	0.000	0.000

--- PRZEBIEG SELEKCJI POSTĘPOWEJ ---

Stepwise Summary

Step	Variable	AIC	SBC	SBIC	R2	Adj. R2
0	Base Model	65159.458	65173.879	NA	0.00000	0.00000
1	H	59233.366	59254.997	NA	0.44723	0.44717
2	albedo	57137.569	57166.410	NA	0.55183	0.55174
3	data_arc	56148.788	56184.839	NA	0.59411	0.59399
4	ad	55972.387	56015.649	NA	0.60128	0.60112
5	n	55844.141	55894.613	NA	0.60644	0.60625
6	i	55741.383	55799.065	NA	0.61055	0.61031
7	a	55670.547	55735.440	NA	0.61337	0.61310
8	e	55509.892	55581.996	NA	0.61961	0.61930
9	n_obs_used	55459.978	55539.292	NA	0.62158	0.62124
10	per_y	55457.068	55543.592	NA	0.62176	0.62139
11	om	55456.591	55550.326	NA	0.62186	0.62144

Final Model Output

Model Summary			
R	0.789	RMSE	3.867
R-Squared	0.622	MSE	14.957
Adj. R-Squared	0.621	Coef. Var	73.275
Pred R-Squared	0.617	AIC	55456.591
MAE	1.770	SBC	55550.326

RMSE: Root Mean Square Error
 MSE: Mean Square Error
 MAE: Mean Absolute Error
 AIC: Akaike Information Criteria
 SBC: Schwarz Bayesian Criteria

ANOVA					
	Sum of Squares	DF	Mean Square	F	Sig.
Regression	245970.357	11	22360.942	1493.217	0.0000
Residual	149570.394	9988	14.975		
Total	395540.750	9999			

Parameter Estimates							
model	Beta	Std. Error	Std. Beta	t	sig	lower	upper
(Intercept)	20.981	1.695		12.375	0.000	17.657	24.304
H	-1.963	0.069	-0.443	-28.647	0.000	-2.098	-1.829
albedo	-18.617	0.417	-0.333	-44.637	0.000	-19.434	-17.799
data_arc	0.000	0.000	0.303	30.550	0.000	0.000	0.000
ad	-5.445	0.658	-0.636	-8.278	0.000	-6.735	-4.156
n	9.973	1.285	0.103	7.763	0.000	7.455	12.491
i	0.057	0.006	0.060	9.005	0.000	0.044	0.069
a	8.158	0.482	0.698	16.932	0.000	7.214	9.103
e	17.569	1.883	0.231	9.331	0.000	13.879	21.260
n_obs_used	0.000	0.000	0.104	7.067	0.000	0.000	0.000
per_y	0.347	0.157	0.113	2.213	0.027	0.040	0.654
om	0.001	0.000	0.010	1.573	0.116	0.000	0.001

Zastosowanie dwóch skrajnie różnych strategii przeszukiwania przestrzeni predyktorów przyniosło identyczny rezultat, co jednoznacznie świadczy o wysokiej stabilności struktury analizowanych danych:

Eliminacja wsteczna (Backward):

Algorytm rozpoczął pracę od modelu pełnego (13 predyktorów). W kroku 1. usunięto zmienną ma (anomalia średnia), co obniżyło kryterium informacyjne Akaikiego (AIC) z 55459.42 do 55457.70.

W kroku 2. usunięto zmienną w (argument peryhelium), co doprowadziło do ostatecznego spadku AIC do poziomu 55456.59.

Selekcja postępową (Forward):

Algorytm startujący od modelu pustego (Base Model) sukcesywnie dołączał zmienne charakteryzujące się najniższą wartością p-value.

Jako pierwszy wprowadzony został kluczowy predyktor fotometryczny – jasność absolutna H (krok 1., skok R^2 do 44.72%), a następnie zdolność odbijania światła albedo (krok 2., wzrost R^2 do 55.18%).

W ostatnim, 11. kroku algorytm dołączył długość węzła wstępującego (om), kończąc procedurę na dokładnie tym samym zestawie 11 predyktorów.

Uzasadnienie astronomiczne usuniętych predyktorów

Z matematycznego punktu widzenia algorytm odrzucił predyktory ma oraz w ze względu na brak ich istotności statystycznej ($p\text{-value} > 0.05$). Ta decyzja ma perfekcyjne uzasadnienie w mechanice nieba:

- **Anomalia średnia (ma):** To parametr określający pozycję asteroidy na orbicie eliptycznej w odniesieniu do całkowicie arbitralnie wybranej epoki czasowej. Wartość ta zmienia się w każdej sekundzie lotu obiektu po trajektorii. Pozycja geometryczna ciała w danym momencie roku nie ma i nie może mieć żadnego wpływu na jego rzeczywisty, fizyczny rozmiar.
- **Argument peryhelium (w):** To kąt określający orientację elipsy orbity w jej własnej płaszczyźnie. Podobnie jak anomalia średnia, jest to czysto przestrzenny parametr orientacyjny, który w żaden sposób nie determinuje procesu formowania się ani gabarytów asteroidy.

Zestawienie i ocena dopasowania modelu końcowego

Usunięcie zbędnych, szumiących zmiennych zoptymalizowało model bez straty jakości predykcji:

Parametr Jakości Modelu	Model Pełny (13 predyktorów)	Model Zredukowany (11 predyktorów)	Efekt i wniosek statystyczny
Współczynnik R^2	0.62190	0.62186	Niemal identyczny. Usunięte zmienne wносиły do modelu mniej niż 0.004% informacji.
Skorygowany Adj. R^2	0.62141	0.62144	Delikatny wzrost. Dowodzi, że redukcja wymiarowości skutecznie ukarała model za nadmiarowe parametry.
Błąd standardowy (RMSE)	3.870 km	3.867 km	Spadek błędu. Przeciętny błąd prognozy średnicy uległ minimalnemu zmniejszeniu.
Kryterium AIC	55459.423	55456.591	Spadek wartości. Jednoznacznie wskazuje model zredukowany jako lepszy.
Kryterium SBC / BIC	55567.578	55550.326	Widoczny spadek. Dowód na korzyść uproszczenia struktury modelu.

Paradoks wskaźnika VIF w regresji krokowej

Analiza parametrów modelu końcowego ujawnia fascynujący fenomen metodologiczny. Choć wcześniejsza analiza VIF wykazała, że zmienne keplerowskie (aphelium ad z VIF = 155.96, pólko a z VIF = 44.96 oraz okres per_y z VIF = 68.37) potężnie współliniują, regresja krokowa oparta o p-value nie usunęła żadnej z nich.

Wynika to z faktu, że algorytmy krokowe patrzą wyłącznie na minimalizację błędów i poziom istotności, ignorując korelację między predyktorami. Dla modelu oznacza to, że te potężnie skorelowane zmienne, działając wspólnie jako system naczyń połączonych, wciąż wnoszą kluczową wartość predykcyjną dla wyznaczania średnicy, mimo że ich indywidualne współczynniki strukturalne pozostają niestabilne matematycznie.

Ludzki błąd selekcji w parametrach obserwacyjnych

Na sam koniec warto spojrzeć na parametry czysto techniczne: rozpiętość łuku obserwacyjnego (*data_arc*) oraz liczbę użytych obserwacji (*n_obs_used*). Oba predyktory okazały się skrajnie istotne statystycznie (p-value < 0.001). Ponieważ ich współczynniki są bliskie zera, ich wpływ widać dopiero przy dużych wartościach (Std. Beta dla *data_arc* wynosi aż 0.303, co czyni go trzecim najsilniejszym predyktorem w modelu).

W rzeczywistości astronomicznej oznacza to, że asteroidy duże, potężne i potencjalnie zagrażające Ziemi są przez ludzkość śledzone przez znacznie większą liczbę dni (*data_arc*) i fotografowane nieporównywalnie częściej (*n_obs_used*) niż małe, bezpieczne i ledwo widoczne kosmiczne odłamki. Model bezbłędnie wychwycił ten błąd selekcji w bazie danych NASA.

4.7. Diagnostyka wpływowa i odstająca

--- PODSUMOWANIE MODELU BAZOWEGO ---

```
Call:
lm(formula = diameter ~ . - q - ma - w, data = df)
```

Residuals:

Min	1Q	Median	3Q	Max
-19.894	-1.157	-0.183	0.889	66.045

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	2.098e+01	1.695e+00	12.375	< 2e-16	***
H	-1.963e+00	6.854e-02	-28.647	< 2e-16	***
albedo	-1.862e+01	4.171e-01	-44.637	< 2e-16	***
e	1.757e+01	1.883e+00	9.331	< 2e-16	***
a	8.158e+00	4.818e-01	16.932	< 2e-16	***
i	5.675e-02	6.302e-03	9.005	< 2e-16	***
om	5.924e-04	3.766e-04	1.573	0.1158	
ad	-5.445e+00	6.578e-01	-8.278	< 2e-16	***
n	9.973e+00	1.285e+00	7.763	9.13e-15	***
per_y	3.468e-01	1.567e-01	2.213	0.0269	*
data_arc	3.156e-04	1.033e-05	30.550	< 2e-16	***
n_obs_used	3.673e-04	5.197e-05	7.067	1.68e-12	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.87 on 9988 degrees of freedom

Multiple R-squared: 0.6219, Adjusted R-squared: 0.6214

F-statistic: 1493 on 11 and 9988 DF, p-value: < 2.2e-16

Po ustaleniu struktury modelu bazowego (11 predyktorów), przeprowadzono głęboką analizę wpływu pojedynczych obserwacji na poszczególne parametry strukturalne (metoda DFBETAs) oraz na globalne prognozy modelu (metoda DFFITS).

--- TOP 5 ANOMALII DLA WSPÓŁCZYNNIKA ALBEDO (DFBETAs) ---

	albedo
7745	-0.5897004
7579	-0.4662092
4926	-0.4195055
6435	-0.3933031
1027	-0.3913465

--- TOP 5 ANOMALII DLA WSPÓŁCZYNNIKA JASNOŚCI H (DFBETAs) ---


	H
7745	-1.5280273
6145	0.9389626
844	-0.8019818
4435	-0.7933388
7352	-0.7738016

Analiza wskaźników DFBETAs (Wpływ na współczynniki beta)

Wskaźnik DFBETAs mierzy, o ile odchyłeń standardowych zmieni się konkretny współczynnik regresji, jeśli usuniemy z próby daną obserwację. Z racji ogromnej liczebności próby ($n = 10000$), rygorystyczny próg odcięcia wynosi 0.02. Algorytm wyizolował najbardziej destrukcyjne anomalie dla dwóch kluczowych zmiennych fizycznych:

- **Wpływ na predyktor jasności (H):** Bezwzględny, legendarnym "winowajcą" w tej kategorii okazała się asteroida o indeksie 7745, dla której wskaźnik DFBETAs osiągnął krytyczną wartość -1.528. Oznacza to, że ta jedna jedyna kosmiczna skała samodzielnie przesuwając współczynnik jasności H o ponad 1.5 raza błędu standardowego w dół. Pozostałe anomalie (6145, 844, 4435, 7352) również silnie polaryzują tę relację, fałszując fundamentalne prawo fotometrii.
- **Wpływ na predyktor albedo:** Wykres dla zmiennej albedo ujawnił, że ten sam obiekt – 7745 (DFBETAs = -0.5897) również tutaj skrajnie zniekształca wagę przypisywaną zdolności odbijania światła. Dowodzi to, że w bazie danych NASA prawdopodobnie znajduje się wąska grupa potężnych, niestandardowych ciał niebieskich, które drastycznie zaburzają estymację najważniejszych parametrów modelu.

Wizualnym i globalnym uzupełnieniem tej analizy parametrów strukturalnych jest ocena łącznego wpływu obserwacji na całą płaszczyznę prognoz za pomocą wskaźnika DFFITS.




Wskaźnik ten pokazuje, o ile odchyleń standardowych przesuwają się prognozy średnicy asteroidy, gdy wykluczamy ją z procesu estymacji. Wyznaczony rygorystyczny tunel dopuszczalnych wahań (czerwone linie poziome 0.07) został całkowicie zdominowany przez pionowe piki anomalii. Obiekt 7745 (zidentyfikowany w DFBETAs) wraz z planetoidą 6927 generują ekstremalnie silny wpływ dodatni (wysokość powyżej 1.5), brutalnie ściągaając globalne prognozy modelu w górę. Z kolei obiekty takie jak 520, 6531, 8315 oraz 8392 generują potężne piki ujemne, sztucznie zaniżając płaszczyznę dopasowania.

Czyszczenie danych za pomocą Odległości Cooka

Aby uzdrowić model, zastosowano globalne kryterium odległości Cooka z progiem $4/n = 0.0004$. Algorytm zidentyfikował i zakwalifikował do usunięcia 371 wartości wpływowych (co stanowi 3.71% wyjściowego zbioru). Usunięcie tej podgrupy pozwoliło na ostateczne odcięcie "grubych ogonów" rozkładu i stabilizację wielowymiarowej płaszczyzny regresji.


Liczba wartości wpływowych do usunięcia (4/n): 371




Graficzne odzwierciedlenie tej procedury doskonale prezentuje wykres odległości Cooka. Linie reprezentujące poszczególne asteroidy masowo przebijają linię progową, która z racji wielkości próby przebiega niemal przy samej osi X. Rekordzistą pod względem destabilizacji modelu jest wspomniany wyżej obiekt 6927 (osiągający $D_i > 0.3$), a zaraz za nim plasują się punkty 7745, 6435 oraz 844.

Aby w pełni zrozumieć fizyczną przyczynę, dla której te 371 obiektów generuje tak potężny, toksyczny wpływ na model, należy przyjrzeć się czystym błędom predykcji na osi zmiennej objaśnianej (Y), które wizualizują wykresy reszt.

Studentized Residuals Plot





Wykres ten krzyżuje resztę studentyzowaną z dźwignią (Leverage), dzieląc przestrzeń na cztery strefy decyzyjne. Specyficzny, uderzający wygląd tej wizualizacji jest bezpośrednim odzwierciedleniem pracy na dużej próbie badawczej i idealnie obrazuje strukturę Układu Słonecznego:

- **Pionowa ściana nakładających się anomalii ($Leverage \approx 0$):**
Stanowi ją zdecydowana większość próby. To gęsty, pionowy mur reprezentujący standardowe asteroidy z Pasa Głównego. Mają one identyczne, przeciętne orbity, stąd ich dźwignia wynosi zero. To jednak z tego muru wystrzeliwują w górę zielone punkty – obiekty o typowych orbitach, ale anomalnych rozmiarach fizycznych.
- **Fioletowa strefa zagrożenia – Obiekt 6927 (Outlier & Leverage):**
Jasno i wyraźnie z tej zbitej masy wyłamuje się samotny punkt 6927 ($Leverage \approx 0.42$, $RStudent \approx 2$), wpadając głęboko w fioletową strefę krytyczną. Łączy on w sobie bardzo nietypową trajektorię orbitalną z dużym błędem oszacowania rozmiaru, przez co wywierał największy destrukcyjny wpływ na całe równanie regresji (co potwierdziła najwyższa igła na wykresie odległości Cooka).

- **Czerwona kotwica – Obiekt 520 (Pure Leverage):** Na skrajnym prawym marginesie wykresu ($Leverage \approx 0.88$) znajduje się odosobniony, czerwony punkt 520. Co fascynujące, jego błąd predykcji jest bliski zeru ($RStudent \approx 0$). Jest to obiekt o unikalnej, skrajnej trajektorii, który z racji swojej całkowitej samotności w przestrzeni zadziałał jak magnes – zmusił płaszczyznę regresji KMNK do przejścia idealnie przez jego środek, zniekształcając parametry strukturalne dla pozostałej, typowej populacji asteroid.

4.8. Porównanie modelu bazowego z ostatecznym modelem końcowym

--- PODSUMOWANIE OSTATECZNEGO MODELU KOŃCOWEGO ---

Call:

```
lm(formula = diameter ~ . - q - ma - w, data = df_clean)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-4.9584	-0.6636	-0.0781	0.5177	13.3696

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.200e+01	2.044e+00	10.763	< 2e-16 ***
H	-1.261e+00	2.941e-02	-42.894	< 2e-16 ***
albedo	-1.442e+01	1.593e-01	-90.502	< 2e-16 ***
e	9.003e+00	1.354e+00	6.650	3.08e-11 ***
a	-1.193e+00	1.298e+00	-0.919	0.3580
i	2.668e-02	2.264e-03	11.784	< 2e-16 ***
om	1.806e-04	1.306e-04	1.382	0.1669
ad	-3.012e+00	4.794e-01	-6.282	3.49e-10 ***
n	3.442e+00	2.055e+00	1.675	0.0939 .
per_y	2.641e+00	3.678e-01	7.181	7.46e-13 ***
data_arc	9.440e-05	4.052e-06	23.297	< 2e-16 ***
n_obs_used	6.796e-04	2.272e-05	29.918	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.315 on 9617 degrees of freedom

Multiple R-squared: 0.8311, Adjusted R-squared: 0.831

F-statistic: 4303 on 11 and 9617 DF, p-value: < 2.2e-16

Na bazie oczyszczonego z 371 anomalii zbioru danych (*df_clean*), liczącego obecnie 9629 obserwacji, ponownie dopasowano model regresji wielorakiej. Wyniki porównawcze okazały się spektakularne:

Parametr Statystyczny	Model Bazowy (Z anomaliami)	Model Końcowy (Po usunięciu 371 anomalii)	Efekt i wniosek analityczny
Współczynnik determinacji R^2	0.6219 (62.19%)	0.8311 (83.11%)	Potężny wzrost o 20.92 p.p. Oczyszczony model wyjaśnia aż 83.11% wariancji wielkości asteroid. Kosmiczny szum został usunięty.
Błąd standardowy reszt (\$RSE\$)	3.870 km	1.315 km	Spadek błędu o 66%! Przeciętny błąd prognozy średnicy zmalał do zaledwie 1.3 km.
Maksymalny błąd błędu (Max Residual)	66.045 km	13.370 km	Ekstremalne niedoszacowania wielkich obiektów zostały całkowicie zredukowane.

Fascynująca zmiana: Jak czyszczenie danych naprawiło fizykę (Prawa Keplera)

Analiza współczynników modelu końcowego ujawnia świetną zmianę strukturalną, która idealnie pokazuje, jak usunięcie anomalii rozwiązało problem współliniowości (VIF):

- **Śmierć zmiennej *a* (Półoś wielka):** W modelu bazowym półoś wielka była bardzo istotna ($t = 16.93$, współczynnik 8.158). W modelu końcowym jej współczynnik zmienił znak na ujemny (-1.193), a zmienna stała się całkowicie **nieistotna** statystycznie (p-value = 0.3580)

- **Wybicie się zmiennej *per_y* (Okres orbitalny):** W tym samym czasie współczynnik okresu orbitalnego wystrzelił z 0.347 do 2.641 i stał się super-istotny (***, $t = 7.181$).

Wyjaśnienie astronomiczne:

Jest to idealny dowód na to, jak potężna korelacja między półosią wielką a okresem orbitalnym (wynikająca z Trzeciego Prawa Keplera) paraliżowała model pełny. Te 371 anomalnych asteroid (prawdopodobnie obiekty o nietypowych, bardzo odległych orbitach kometarnych) sztucznie utrzymywały fałszywą istotność zmiennej *a*. Po ich usunięciu algorytm KMNK odzyskał stabilność matematyczną – poprawnie uznał, że półoś wielka *a* dubluje informację i przekazał całą siłę predykcyjną do okresu orbitalnego (*per_y*).

Ostateczne równanie modelu końcowego:

$$\text{diameter} = 22.00 - 1.261 \cdot H - 14.42 \cdot \text{albedo} + 9.003 \cdot e - 3.012 \cdot ad + 2.641 \cdot \text{per}_y + \dots$$

Wszystkie kluczowe zmienne fizyczne (*H*, *albedo*) oraz orbitalne (*e*, *ad*, *per_y*) są wysoce stabilne, a ich błędy standardowe drastycznie zmalały, dając nam niesamowicie precyzyjne narzędzie astrofizyczne.

4.9. Wyznaczenie zbioru stosowalności modelu wielorakiego na podstawie przedziałów ufności i predykcji

W celu ostatecznego zweryfikowania poprawności i sensu aplikacyjnego ostatecznego modelu wielorakiego, wyznaczono 95-procentowe przedziały ufności oraz predykcji. Obliczeń dokonano dla profilu „przeciętnej” asteroidy, podstawiając pod 11 predyktorów ich średnie wartości empiryczne z oczyszczonego zbioru danych.

Wyniki empiryczne

--- MODEL WIELORAKI KOŃCOWY (Dla średnich wartości cech) ---

Przedział ufności dla płaszczyzny regresji (fit, lwr, upr):

	fit	lwr	upr
1	4.719737	4.693478	4.745997

```
Przedział predykcji dla nowej obserwacji (fit, lwr, upr):  
      fit      lwr      upr  
1 4.719737 2.142812 7.296662
```

Dla statystycznie średniego obiektu kosmicznego, model wieloraki wyznaczył teoretyczną średnicę (wartość dopasowaną) wynoszącą 4.72 km. Uzyskane pasma niepewności prezentują się następująco:

- **95% Przedział ufności (confidence):** PU = [4.69 km; 4.75 km]
- **95% Przedział predykcji (prediction):** PP = [2.14 km; 7.30 km]

Interpretacja statystyczna i uzasadnienie fizyczne

1. Ekstremalna precyzja linii regresji: Przedział ufności dla płaszczyzny regresji charakteryzuje się minimalną rozpiętością (zaledwie około 52 metrów). Dowodzi to, że dzięki olbrzymiej liczbie obserwacji oraz usunięciu szumiących anomalii, wielowymiarowe położenie naszej płaszczyzny regresji zostało oszacowane z niemal absolutną dokładnością statystyczną.

2. Uzdrawienie fizycznego sensu modelu (Brak wartości ujemnych): Najważniejszy wniosek płynie z analizy przedziału predykcji dla nowej, jednostkowej obserwacji. Choć pasmo to z natury jest szersze (rozpiętość ok. 5.15 km) z powodu uwzględnienia nieprzewidywalnej wariancji resztowej, to jego dolna granica wynosi 2.14 km i jest wartością dodatnią.

Definicja zbioru sensowności modelu wielorakiego – porównanie

Wynik ten stanowi ostateczny dowód na wyższość modelu regresji wielorakiej nad modelem prostym i precyzyjnie definiuje jego zbiór stosowności:

- W modelu regresji prostym, dla średniej asteroidy, dolna granica predykcji wynosiła ujemne -3.89 km, co stanowiło fizyczny absurd i dyskwalifikowało model.
- W modelu wielorakim, dzięki okiełznaniu brakującej wariancji za pomocą albedo geometrycznego oraz parametrów orbitalnych, błąd standardowy reszt (RSE) spadł z 4.68 km do zaledwie 1.315 km. Spowodowało to tak silne zwężenie pasa predykcji, że dolna granica nie wkracza w obszar liczb ujemnych.

Wniosek końcowy: Model regresji wielorakiej zachowuje pełen sens matematyczny, logiczny i fizyczny dla globalnego zbioru typowych ciał niebieskich. W przeciwieństwie do modelu prostego, potrafi on zagwarantować realne, fizycznie możliwe (dodatnie) prognozy rozmiaru dla nowo odkrywanych obiektów o przeciętnej charakterystyce, co czyni go w pełni bezpiecznym i rzetelnym narzędziem astrofizycznym.

4.10. Ewaluacja hipotez i odpowiedzi na pytania badawcze

Przeprowadzona analiza regresyjna (prosta oraz wieloraka) pozwoliła na udzielenie precyzyjnych i empirycznie uzasadnionych odpowiedzi na pytania badawcze postawione we wstępie tego sprawozdania:

1. Odpowiedź na pytanie pierwsze:

Czy bazując wyłącznie na jasności absolutnej (H), jesteśmy w stanie precyzyjnie aproksymować średnicę asteroidy?

Analiza modelu regresji prostej wykazała, że jasność absolutna (H) jest kluczowym, fundamentalnym predyktorem rozmiaru ciał niebieskich, jednak nie pozwala na w pełni precyzyjną prognozę. Wyjściowy model prosty wyjaśniał **jedynie 44,72%** całkowitej wariancji rozmiaru, generując przy tym błąd standardowy reszt na poziomie **4,68 km**. Co ważniejsze, próba wymuszenia relacji liniowej tam, gdzie w rzeczywistości fizycznej zachodzi zależność wykładnicza, doprowadziła do drastycznych błędów nieliniowości. Sama informacja o blasku obiektu bez uwzględnienia jego właściwości powierzchniowych i orbitalnych jest niewystarczająca do dokładnego modelowania gabarytów kosmicznych skał.

2. Odpowiedź na pytanie drugie:

W jakim stopniu rozbudowanie struktury o dodatkowe predyktory orbitalne podnosi zdolności wyjaśniające modelu?

Rozbudowanie modelu o parametry mechaniki nieba oraz parametry techniczne samych obserwacji przyniosło radykalny i spektakularny skok jakości predykcyjnej. Wprowadzenie dodatkowych zmiennych podbiło współczynnik determinacji w surowym modelu wielorakim do poziomu 62,19%. Prawdziwy przełom przyniósł jednak kolejny krok – wielowymiarowa diagnostyka wartości wpływowych, która wyizolowała 371 najbardziej destrukcyjnych obiektów. Po ich wykluczeniu, ostateczny model końcowy osiągnął współczynnik R^2 na poziomie **83,11%**, a błąd standardowy reszt (RSE) spadł do zaledwie **1,315 km**. Oznacza to, że uwzględnienie geometrii trajektorii i albedo pozwoliło na zredukowanie błędu o ponad 71% w stosunku do regresji prostej i precyzyjne „okiełznanie” badanego zjawiska fizycznego.

3. Odpowiedź na pytanie trzecie:

Które parametry opisujące mechanikę nieba wykazują najsilniejszą współliniowość i jak wpływa to na ostateczny model?

Analiza wskaźnika VIF ujawniła potężne zjawisko współliniowości pomiędzy zmiennymi keplerowskimi, nierozzerwalnie połączonymi ze sobą prawami fizyki (Trzecie Prawo Keplera oraz geometria elipsy). Wskaźniki VIF dla odległości

w aphelium ($ad = 155,96$), okresu orbitalnego ($per_y = 68,37$) oraz półosi wielkiej ($a = 44,96$) drastycznie przekroczyły bariery statystyczne. Co ciekawe, usunięcie 371 anomalnych asteroid za pomocą kryterium odległości Cooka samodzielnie rozwiązało problem współliniowości. Po oczyszczeniu próby algorytm KMNK odzyskał stabilność – poprawnie zidentyfikował, że półoś wielka a dubluje informacje i uczynił ją całkowicie nieistotną statystycznie ($p\text{-value} = 0,358$), przenosząc całą siłę predykcyjną na okres orbitalny (per_y). Eliminacja anomalii pozwoliła na naturalne „wyprostowanie” relacji fizycznych wewnątrz modelu.

4.11. Podsumowanie i wnioski strukturalne modelu regresji wielorakiej

Ostateczny, zredukowany model regresji wielorakiej oparty na 11 predyktorach i oszacowany na oczyszczonej próbie badawczej charakteryzuje się dobrymi właściwościami statystycznym. Współczynnik determinacji wynoszący 83,11% dowodzi, że model w wysoce satysfakcjonującym stopniu opisuje strukturę zmienności fizycznej średnicy asteroid.

Przeprowadzona szeroka diagnostyka z użyciem wskaźników DFBETAs, DFFITS oraz reszt studentyzowanych jednoznacznie udowodniła, że surowa baza danych NASA zawierała podgrupę specyficznych obiektów (takich jak rekordowe punkty 6927, 7745 czy 520), które z racji unikalnych orbit lub skrajnego składu chemicznego wywierały destrukcyjny wpływ na stabilność estymatorów KMNK. Dopiero ich automatyczne wykluczenie doprowadziło do drastycznego obniżenia błędu standardowego reszt ($RSE = 1,315$ km), czyniąc model narzędziem wysoce precyzyjnym.

Należy zauważyć, że pomimo eliminacji anomalii, formalne założenia KMNK dotyczące normalności rozkładu błędu oraz homoskedastyczności pozostają **naruszone**. Jednak w kontekście pracy na tak gigantycznej próbie badawczej ($n = 9629$ po czyszczeniu), w oparciu o Centralne Twierdzenie Graniczne (CTG) oraz asymptotyczne właściwości estymatorów, naruszenia te nie dyskwalifikują modelu. Uzyskane równanie regresji wielorakiej jest w pełni poprawne strukturalnie, stabilne i gotowe do dokonywania prognoz dla nowych ciał niebieskich.

5. Podsumowanie Końcowe i Perspektywa Astrofizyczna

Zwieńczeniem przeprowadzonego modelowania statystycznego jest spojrzenie na uzyskane wyniki przez pryzmat współczesnej astrofizyki. Cała ścieżka analityczna – od prostego, jednowymiarowego ujęcia do zaawansowanej, wielowymiarowej płaszczyzny regresji – doskonale obrazuje, jak potężnym narzędziem jest poprawnie zoptymalizowana statystyka.


Współczesna inżynieria kosmiczna staje przed ogromnym wyzwaniem: bezpośredni pomiar fizycznych rozmiarów asteroid za pomocą aparatury optycznej (np. optyki adaptatywnej czy misji kosmicznych) jest procesem bardzo kosztownym i rzadkim. Teleskopy najczęściej dostarczają nam jedynie pośrednie dane – rejestrują chwilowy błysk światła (jasność H) oraz serię pozycji na niebie, z których mechanika nieba wylicza parametry orbitalne bryły. Ten projekt udowodnił, że krzyżując te dwa proste strumienie danych (fotometrię i geometrię orbit), jesteśmy w stanie na odległość milionów kilometrów określić fizyczną średnicę kosmicznej skały z dokładnością do około 1300 metrów.

Astronomiczna ciekawostka: Jak albedo „złamało kod” wariacji?

Najbardziej fascynującym momentem regresji wielorakiej było wprowadzenie zmiennej albedo, która gwałtownie podniosła jakość modelu. Wynika to bezpośrednio z faktu, że populacja asteroid w naszym Układzie Słonecznym jest skrajnie zróżnicowana pod względem budowy geologicznej.

W przestrzeni kosmicznej dominują dwa główne typy ciał niebieskich:

- **Asteroidy typu C (węglowe):** Są czarne jak węgiel drzewny, ich albedo wynosi zaledwie około 0,03 - 0,05. Odbijają znikomą ilość światła.
- **Asteroidy typu S (krzemianowe):** Są jasne, kamienne lub metaliczne, o albedo sięgającym 0,15 - 0,25.



Fizyczne zróżnicowanie powierzchni i zdolności odbijania światła (albedo).
Po lewej: skrajnie ciemna asteroida węglowa typu C – Bennu (albedo ≈ 0.04).
Po prawej: jasna, bogata w krzemiany asteroida typu S – Itokawa (albedo ≈ 0.23).
Źródło: NASA / JAXA.

Wyobraźmy sobie dwie asteroidy podróżujące obok siebie w Pasie Głównym, które w obiektywie ziemskiego teleskopu dają dokładnie taki sam błysk światła (identyczna jasność H). Bez uwzględnienia zmiennej albedo model prosty traktował je identycznie. Statystyka wieloraka obnażyła jednak prawdę: aby czarna asteroida węglowa (typ C) błysnęła tak samo mocno jak jasna skała krzemianowa (typ S), musi być od niej w rzeczywistości fizycznej kilkukrotnie większa. Model matematyczny bezbłędnie zakodował tę astronomiczną zależność w postaci potężnego, ujemnego współczynnika przy zmiennej albedo ($\beta = -14,42$).

Znaczenie praktyczne dla ludzkości

Wiedza uzyskana dzięki temu modelowi ma fundamentalne, strategiczne znaczenie w dwóch kluczowych obszarach:

- **Obrona planetarna:** W przypadku wykrycia nowej planetoidy zmierzającej w kierunku Ziemi, szybkie podstawienie jej parametrów orbitalnych i fotometrycznych do wyznaczonego w tym projekcie równania końcowego pozwala w kilka sekund oszacować jej masę i gabaryty. To z kolei decyduje o energii potencjalnego uderzenia i pozwala na natychmiastowe zaplanowanie misji ewentualnej deflekcji (jak w przypadku słynnego testu NASA DART).

- **Górnictwo kosmiczne:** Dynamicznie rozwijający się sektor komercyjnej eksploatacji kosmosu opiera się na zdalnej selekcji celów. Dokładne oszacowanie objętości bryły (na podstawie wyliczonej średnicy) pozwala na wstępną wycenę wartości surowcowej złoża (np. platynowców czy żelaza) przed wysłaniem kosztownych sond badawczych.

Słowo końcowe: Statystyka opisowa i matematyczna, choć z natury operuje na suchych liczbach i wektorach błędów, po połączeniu z prawami natury staje się potężnym “teleskopem” matematycznym. Pozwala ona ludzkości bez opuszczania powierzchni Ziemi bezpiecznie i precyzyjnie mapować, mierzyć i rozumieć mroczną przestrzeń otaczającego nas kosmosu.