

Analiza eksploracyjna

Autor: Wiktoria Awramik

1. Wstęp

Temat analizy:

Eksploracyjna analiza danych dotyczących globalnych misji kosmicznych w latach 1957–2022.

Cel pracy:

Celem projektu jest przeprowadzenie analizy opisowej wybranego zbioru danych. Praca ma na celu zbadanie historycznych trendów w podboju kosmosu, ze szczególnym uwzględnieniem wskaźników sukcesu misji oraz nakładów finansowych ponoszonych przez poszczególne państwa i prywatne agencje kosmiczne. W ramach projektu zrealizowano klasyfikację zmiennych, obliczenia podstawowych statystyk opisowych oraz przygotowano wizualizacje ukazujące zależności między badanymi cechami.

Powód wyboru danego zbioru danych:

Większość standardowych analiz statystycznych opiera się na mocno wykorzystywanych zbiorach danych (takich jak ceny nieruchomości czy parametry medyczne). Zbiór dotyczący misji kosmicznych został wybrany ze względu na jego unikalną tematykę, która pozwala połączyć analizę kosztów (zmienne ilościowe) z historycznymi i technologicznymi aspektami poszczególnych lotów (zmienne jakościowe). Dodatkowo, dynamika zmian w sektorze kosmicznym (przejście od misji rządowych do komercyjnych) stanowi doskonałe tło do poszukiwania ciekawych zależności w danych.

2. Opis zbioru danych

Nazwa zbioru danych:

Space Missions (1957-2022)

Źródło danych:

Zbiór pochodzi bezpośrednio z serwisu Maven Analytics (Data Playground), aczkolwiek dostępny jest również w tej samej formie na platformie Kaggle.

Link do danych:

[Space Missions Dataset](#)

Podstawowe wymiary zbioru:

Liczba obserwacji: 4630

Liczba zmiennych: 10

Ogólny opis:

Zbiór stanowi historyczny rejestr startów rakiet kosmicznych na świecie od początku wyścigu kosmicznego (1957 rok) aż do roku 2022.

Zawiera on informacje o tym, kto organizował lot, z jakiego miejsca wystartowała rakietą, kiedy wystartowała, nazwę rakiety, nazwę misji, status, ile kosztowała misja oraz czy zakończyła się ona sukcesem.

Opis analizowanych zmiennych:

Do dalszej analizy wybrano następujące zmienne, które najlepiej oddają charakterystykę problemu:

- **Nazwa zmiennej:** *Company Name*
Typ: Jakościowa
Znaczenie: Wskazuje organizację lub firmę odpowiedzialną za start rakiety (np. NASA, Roscosmos, SpaceX). Pozwala na porównanie skuteczności poszczególnych agencji.
- **Nazwa zmiennej:** *Mission Status*
Typ: Jakościowa
Znaczenie: Określa wynik misji (np. Sukces, Porażka, Częściowa porażka). Jest to kluczowa zmienna do analizy bezpieczeństwa i niezawodności lotów.
- **Nazwa zmiennej:** *Price*
Typ: Ilościowa ciągła
Jednostka miary: Miliony dolarów amerykańskich (USD)
Znaczenie: Reprezentuje koszt danej misji. Pozwala na badanie budżetów agencji oraz sprawdzanie, czy droższe misje charakteryzują się większym odsetkiem sukcesów.
- **Nazwa zmiennej:** *Year* (zmienna wyodrębniona w fazie przygotowania danych z kolumny *Date*)
Typ: Ilościowa skokowa
Jednostka miary: Rok

Znaczenie: Umożliwia śledzenie trendów w czasie – np. intensywności startów w okresie zimnej wojny względem czasów współczesnych.

3. Przygotowanie danych

Wczytany zbiór danych wymagał wstępnego przygotowania oraz oczyszczenia, aby umożliwić poprawne przeprowadzenie analizy statystycznej. Wykonano następujące kroki:

Analiza braków danych:

W kolumnie *Price* brakowało 3365 rekordów danych. Wynika to z faktu, że koszty starszych, historycznych misji (np. w czasach zimnej wojny z udziałem ZSRR) rzadko były publicznie udostępniane.

Zdecydowałam się nie usuwać tych wierszy z całego zbioru, ponieważ zawierają one cenne informacje o statusie misji czy operatorze. Obserwacje z brakującą ceną będą po prostu pomijane wyłącznie w tych punktach analizy, które dotyczą nakładów finansowych (pozostała próba 1265 obserwacji jest w pełni wystarczająca do wnioskowania).

Przekształcenia typów zmiennych:

W oryginalnym pliku zmienna *Price* była zapisana jako tekst (zawierała przecinki oddzielające tysiące, np. "1,160.00"). Za pomocą odpowiednich funkcji usunięto przecinki i przekonwertowano kolumnę na ciągłą zmienną numeryczną.

Tworzenie nowych zmiennych:

Z kolumny *Date* (zawierającej dokładną datę startu) wyodrębniłam sam rok, tworząc nową, skokową zmienną ilościową *Year*. Dzięki temu zbiór spełnia wymóg posiadania dwóch zmiennych ilościowych (*Price* oraz *Year*), co ułatwi m.in. badanie historycznych trendów i tworzenie wykresów rozrzutu.

W analizie pominięto mało istotne technicznie kolumny, takie jak *Time* czy *Location*, skupiając się na głównych metrykach lotu.

Po wykonaniu niezbędnych przekształceń, gotowy do analizy zbiór został zapisany do nowego pliku *space_missions_clean.csv*, na którym prowadzono dalsze obliczenia.

4. Statystyki opisowe

	Miara_Statystyczna	Cena_Mln_USD	Rok_Startu
1	Srednia	128.30	1989.62
2	Mediana	63.23	1987.00
3	Dominanta	450.00	2021.00
4	Minimum	2.50	1957.00
5	Maksimum	5000.00	2022.00
6	Rozstep	4997.50	65.00
7	Kwartyl_Dolny_Q1.25%	30.00	1973.00
8	Kwartyl_Gorny_Q3.75%	115.00	2007.00
9	Rozstep_Miedzykwartylowy_IQR	85.00	34.00
10	Wariancja	65930.66	375.31
11	Odchylenie_Standardowe	256.77	19.37
12	Wspolczynnik_Zmiennosci_Proc	200.13	0.97
13	Skosnosc	11.67	0.25
14	Kurtoza	205.16	-1.27

Analiza kosztów misji (Zmienna *Price* w mln USD)

Miary tendencji centralnej (Średnia, Mediana, Dominanta):

Średni koszt misji kosmicznej wynosi 128,30 mln USD. Jednakże, wartość ta jest silnie zawyżona przez pojedyncze, ekstremalnie drogie programy z czasów zimnej wojny.

Znacznie lepszą miarą przeciętną jest tu mediana wynosząca 63,23 mln USD, co oznacza, że dokładnie połowa wszystkich misji kosztowała poniżej tej kwoty.

Niezwykle interesującą wartością jest natomiast dominanta (najczęściej powtarzająca się wartość w zbiorze), która wynosi aż 450 mln USD. Wynika to z faktu, że właśnie na taką kwotę wyceniano ustandaryzowany koszt startu amerykańskich wahadłowców w ramach wieloletniego programu Space Shuttle (NASA), który obejmował ponad 130 lotów.

Miary zróżnicowania (Odchylenie, IQR, Rozstęp):

Koszty misji charakteryzują się gigantycznym rozstrzałem. Całkowity rozstęp wynosi aż 4997,5 mln USD (różnica między najtańszą misją za 2,5 mln a najdroższą za równe 5000 mln USD).

Odchylenie standardowe to aż 256,77 mln, co daje współczynnik zmienności na poziomie 200,13%. Tak wysoki wynik świadczy o skrajnej niejednorodności kosztów w sektorze kosmicznym. Niemniej jednak, rozstęp międzykwartylowy (IQR) wynosi zaledwie 85 mln USD, co pokazuje, że 50% "typowych"

środkowych misji mieści się w dość zwartym przedziale od 30 do 115 mln USD.

Kształt rozkładu (Skośność, Kurtoza):

Rozkład cen jest ekstremalnie asymetryczny prawostronnie (skośność rzędu 11,67). Oznacza to długi ogon po prawej stronie wykresu – zdecydowana większość misji jest stosunkowo tania, a średnią ciągną w górę nieliczne super-projekty. Kurtoza wynosi aż 205,16, co potwierdza potężną koncentrację typowych wartości wokół mediany przy jednoczesnym występowaniu "grubych ogonów" (wartości odstających).

Analiza rozkładu lotów w czasie (Zmienna Year)

Choć obliczanie klasycznych statystyk dla lat może wydawać się nieintuicyjne, w tym przypadku pozwala na analizę historycznego zagęszczenia misji kosmicznych.

Środek ciężkości i dominanta:

Mediana wynosząca 1987 rok mówi nam, że połowa wszystkich odnotowanych w zbiorze startów rakiet odbyła się przed końcem lat 80. (era Zimnej Wojny i wyścigu zbrojeń), a połowa później.

Niezwykle interesująca jest jednak dominanta – najwięcej startów odbyło się w roku 2021. Pokazuje to wyraźnie "renesans" branży kosmicznej i ogromny wpływ współczesnych firm komercyjnych (tzw. zjawisko New Space).

Zróźnicowanie lotów:

Środkowe 50% wszystkich misji kosmicznych odbyło się na przestrzeni 34 lat (IQR dla lat 1974–2008). Niska ujemna kurtoza (-1,27) wskazuje na rozkład spłaszczony – co oznacza, że po początkowym boomie w latach 60. i 70., loty w kosmos stały się zjawiskiem w miarę równomiernie rozłożonym w czasie, by dopiero w ostatnich latach ponownie drastycznie przyspieszyć.

Analiza zmiennej jakościowej (Zmienna Mission Status)

	Status	Liczebnosc	Czestosc	Procent
1	Failure	357	0.0771	7.71
2	Partial Failure	107	0.0231	2.31
3	Prelaunch Failure	4	0.0009	0.09
4	Success	4162	0.8989	89.89

--- DOMINANTY JAKOŚCIOWE ---

Dominanta dla statusu Misji: Success

Liczebności i Udziały procentowe: Dominantą dla tej zmiennej jest jednoznacznie kategoria Success (sukces). Stanowi ona aż 89,89% wszystkich obserwacji (4162 starty).

Interpretacja:


Sektor kosmiczny, mimo swojej technologicznej złożoności i pracy w ekstremalnych warunkach, charakteryzuje się ogromną niezawodnością. Całkowitą porażką (Failure) zakończyło się zaledwie 7,71% misji (357 przypadków).

Wyniki te dobitnie pokazują, że inżynieria lotnicza wypracowała bardzo rygorystyczne i skuteczne procedury bezpieczeństwa.

Częściowe porażki lub awarie przed startem są minimalne i łącznie stanowią zaledwie 2.4% (111 przypadków). Widać więc jak dokładny jest proces przygotowań oraz jak rozważnie podchodzi się do tematu (bezpieczeństwo, koszt, potencjalne straty), przed podjęciem jakichkolwiek kroków.

5. Wizualizacja danych

Histogram:



Komentarz:


Wykres przedstawia rozkład częstotliwości kosztów misji. Z uwagi na obecność ekstremalnych wartości odstających (rzędu 5000 mln USD), zastosowałam logarytmizację osi X oraz ręcznie zagęściłam jej znaczniki, co pozwoliło "otworzyć" środkową część wykresu i uczynić go czytelnym.

Interpretacja:

Analizując histogram, można zaobserwować niezwykle interesujące zjawisko trójmodalności rozkładu, czyli występowania trzech wyraźnych wypiętrzeń. Pierwszy, niższy "garb" znajduje się w przedziale tanich misji (między 25 a 50 mln dolarów). Drugie, najwyższe wypiętrzenie dominuje w okolicach 60 mln dolarów (co idealnie pokrywa się z wyliczoną wcześniej medianą równą 63 mln).

Z kolei trzeci, bardzo wyizolowany szczyt, grupuje się ściśle wokół kwoty 450-500 mln dolarów (co odpowiada naszej dominancie).

Taki kształt wykresu jednoznacznie sugeruje, że nasza próba jest wysoce niejednorodna i składa się z trzech zupełnie różnych segmentów rynku. Aby zidentyfikować te segmenty, konieczne jest pogłębienie analizy i wygenerowanie wykresu dekompozycji z uwzględnieniem zmiennej jakościowej (np. nazwy organizacji).



Wykres uzupełniający: Rozkład kosztów misji z podziałem na agencje

Komentarz:


Aby wyjaśnić skąd wzięły się trzy szczyty zaobserwowane na głównym histogramie, wygenerowałam nałożony na siebie (skumulowany) rozkład kosztów dla czterech najaktywniejszych podmiotów w zbiorze.

Interpretacja:

Wykres ten pozwala zrozumieć analizowany zbiór i wprost weryfikuje pochodzenie wyliczonych miar statystycznych, wskazując istnienie trzech oddzielnych segmentów rynkowych:

- **Segment budżetowy (ok. 30 mln USD):** Pierwszy szczyt jest w przeważającej mierze generowany przez chińską agencję państwową CASC. Oferuje ona wysoce konkurencyjne cenowo misje (rodzina rakiet Długi Marsz), które stanowią najtańszą opcję na rynku.
- **Segment komercyjny (ok. 60 mln USD):** Środkowy, największy szczyt (nasza mediana) to domena nowoczesnych firm komercyjnych, na czele ze SpaceX. Wysoka standaryzacja rakiet Falcon 9 tworzy niezwykle przewidywalny i stabilny przedział cenowy.
- **Segment historyczno-rządowy (450 mln USD):** Trzeci, potężny szczyt należy w 100% do agencji NASA. Odpowiada on historycznemu, z góry założonemu kosztowi startu amerykańskich

wahadłowców (program Space Shuttle), który ustanowił dominantę całego zbioru.



Komentarz:

Wykres pozwala w intuicyjny sposób porównać miary tendencji centralnej oraz zróżnicowanie środków 50% obserwacji (wysokość kolorowego pudełka to rozstęp międzykwartyłowy). Kropki powyżej/poniżej "wąsów" reprezentują wartości odstające.

Interpretacja:

Dokładna analiza wizualna wykresu pozwala na wyciągnięcie następujących wniosków o strukturze rynku:

NASA (Anomalia statystyczna): Rozkład dla amerykańskiej agencji ma całkowicie unikalny kształt – pudełko "skompresowało się" do pojedynczej, grubej linii na poziomie 450 mln USD.

Oznacza to, że rozstęp międzykwartyłowy wynosi niemal zero, a zdecydowana większość lotów NASA kosztowała dokładnie tyle samo.

Jest to wizualny ślad wieloletniego, ustandaryzowanego programu wahadłowców (Space Shuttle).

Widoczna nad pudełkiem jest również pojedyncza, czarna kropka lekko

powyżej wartości 1000 mln, która stanowi jedyną wartość odstającą w tej grupie.

SpaceX oraz CASC (Liderzy niskich kosztów): Obie organizacje zajmują najniższe segmenty cenowe.

Chińskie CASC posiada najniższą medianę (ok. 30 mln USD).

Z kolei pudełko dla SpaceX jest niezwykle krótkie (spłaszczone w okolicach 60 mln USD), co dowodzi bardzo wysokiej standaryzacji kosztów – ich loty są wysoce powtarzalne cenowo.

Dodatkowo warto zauważyć, że obie te firmy mają wartości odstające sporo poniżej 10 mln – są to ich najtańsze misje, dość niespotykane na tle innych organizacji.

ULA (Zwarty, średni segment): United Launch Alliance operuje w stosunkowo wąskim i przewidywalnym paśmie kosztów. Ich pudełko jest zwarte i mieści się głównie w przedziale 100-150 mln USD. Widoczna powyżej górnego wąsa czarna kropka (sięgające ok. 350 mln) to prawdopodobnie rzadsze loty w najcięższych wariantach ich rakiet.


Arianespace (Największe zróżnicowanie): Europejska agencja jako jedyna posiada bardzo wysokie pudełko, zaczynające się znacznie poniżej 100 mln, a kończące na 200 mln USD. Tak duży rozstęp międzykwartylowy udowadnia, że Arianespace w przeciwieństwie do SpaceX nie stawia na ujednolicenie, lecz korzysta z najszerzego wachlarza rakiet o skrajnie różnych kosztach obsługi.

Identyfikacja wartości odstających:

Aby zidentyfikować do jakich programów należą wartości skrajnie odstające, przeprowadziłam dodatkowe filtrowanie rekordów w bazie danych. Pokazało ono, że:

- Ekstremum dla NASA (ponad 1000 mln USD) to misje historycznego programu Apollo z użyciem ciężkich rakiet nośnych Saturn V.
- Wartość odstająca firmy ULA (350 mln USD) należy do misji wykorzystującej najcięższy, rzadszy wariant rakiety Delta IV Heavy.
- Niezwykle tanie anomalie w dolnych partiach wykresu (poniżej 10 mln USD) to m.in. wczesne (2006 - 2009), testowe loty rakiet Falcon 1 (SpaceX) z początków istnienia firmy.
W sytuacji CASC odstające, bardzo niskie wartości to koszty rzędu 5.3 mln USD na całkiem nowe misje Long March 11 przeprowadzane w latach 2015 - 2022. Natomiast wartość 7.5 mln USD to koszt misji z rakieta Jielong-1 w roli głównej, która wystartowała w 2019 roku.

Violin plot:



Wykres skrzypcowy (Zmienna ilościowa vs jakościowa: Rok startu vs Status)

Komentarz:

Wybrałam wykres skrzypcowy, ponieważ łączy on w sobie zalety klasycznego boxplota (pozwala odczytać medianę i kwartyle dzięki zagnieżdżonej wewnątrz miniaturowej skrzynce) z wykresem gęstości (szerokość "skrzypiec" pokazuje, w których latach dany status występował najczęściej).

Interpretacja:

Wykres ten doskonale obrazuje, jak rozwijał się poziom bezpieczeństwa w sektorze kosmicznym na przestrzeni dekad:

Wąska "talía" sukcesów w środku osi: Skrzypce dla kategorii "Success" są najszersze w swoich dolnych partiach (lata 60. i 70. - Zimna Wojna) oraz w partiach górnych (czasy współczesne, po roku 2010), a wyraźnie zwężają się w latach 90.


Obrazuje to wspomniane wcześniej zmniejszenie nakładów na loty kosmiczne po zakończeniu wyścigu zbrojeń i ich późniejszy komercyjny rozkwit. Mediana sukcesów przypada na koniec lat 80.

Gęstość porażek ("Failure"): Kształt skrzypiec dla porażek całkowitych i częściowych ulega silnemu poszerzeniu w dolnej części wykresu.

Mediana dla "Failure" to zaledwie rok 1971, a 75% wszystkich historycznych awarii wydarzyło się przed końcem lat 90.

Wniosek końcowy: Zwężająca się ku górze struktura "Failure" w zestawieniu z poszerzającą się górą "Success" stanowi wizualny i statystyczny dowód na ogromny postęp inżynieryjny – z biegiem lat starty rakiet stały się zjawiskiem znacznie rzadszym jeśli chodzi o wskaźnik awaryjności, a dzisiejsza inżynieria jest bez porównania bardziej niezawodna niż w erze wczesnego podboju kosmosu.

Scatter plot:



Komentarz:

Wykres rozrzutu to idealne narzędzie do wstępnego zbadania korelacji między dwiema zmiennymi ilościowymi. Dla ułatwienia interpretacji, na chmurę punktów nałożono dodatkowo czerwoną linię trendu.


Interpretacja:

Rozkład punktów na wykresie pozwala zaobserwować historyczną ewolucję rynku kosmicznego. Gęsta chmura punktów po prawej stronie osi X wskazuje na drastyczny wzrost częstotliwości lotów kosmicznych w ostatnich dwóch dekadach (szczególnie w okolicach 2020 roku).

Kluczowym elementem wykresu jest jednak czerwona linia trendu. Posiada ona zauważalne nachylenie ujemne. Wskazuje to na istnienie słabej, ujemnej korelacji między rokiem a ceną. Oznacza to, że pomimo dużej wariacji kosztów w każdym roku, średni koszt wysłania ładunku w kosmos wykazuje tendencję spadkową.

Jest to dowód na postępującą optymalizację, a także komercjalizację technologii kosmicznych, które z biegiem lat stają się coraz bardziej przystępne cenowo.

Bar plot:



Komentarz:

Przeprowadziłam transformację pojedynczych lat na pełne dekady i na tej podstawie stworzyłam klasyczny wykres słupkowy. Pozwala on "wygładzić" chwilowe, roczne wahania i w bardzo czytelny sposób pokazuje długoterminowe, ważne trendy historyczne.

Interpretacja:

Rozkład słupków na osi czasu układa się w charakterystyczny kształt, który można podzielić na trzy wyraźne epoki historyczne:

Złota era wyścigu zbrojeń (Lata 60. i 70.): Wykres bezwzględnie dominuje w lewej części. Szczytowy moment to lata 70. (ok. 1000 startów). Jest to

twardy dowód statystyczny na ogromną intensywność Wyścigu Kosmicznego między USA a ZSRR (programy takie jak Apollo czy Gemini).


Zapaść i stagnacja (Lata 80. – 2000.): Zaczynając od lat 80., obserwujemy utrzymujący się spadek liczby misji, który osiąga swoje absolutne dno w dekadzie lat 2000 (nie licząc samych początków przygody z podróżami w kosmos w latach 50). Obrazuje to gwałtowne cięcia budżetowe po zakończeniu Zimnej Wojny i wyraźne wyhamowanie państwowych programów badawczych.

Era "New Space" (Lata 2010. i 2020.): Odwrócenie trendu spadkowego widać wyraźnie w dekadzie lat 2010.

Niezwykle interesujący z analitycznego punktu widzenia jest jednak ostatni słupek (lata 2020.). Choć wizualnie jest niższy (ok. 400 startów), należy zaznaczyć, że obejmuje on zaledwie trzy pierwsze lata tej dekady (dane do 2022 roku włącznie). Wygenerowanie tak ogromnej liczby startów w tak krótkim czasie oznacza, że dzisiejsza roczna częstotliwość lotów jest najwyższa w historii. Udowadnia to gigantyczny wpływ komercjalizacji sektora (firm takich jak SpaceX) na dostępność misji kosmicznych.

Pie chart:

Procentowy udział statusów misji



Komentarz:

Wykres ten stanowi doskonałe podsumowanie wyliczonych na początku analizy częstości dla zmiennej jakościowej *Success*. Pozwala on na natychmiastową ocenę proporcji między sukcesami a porażkami, potwierdzając poprzednie obliczenia.

Interpretacja:

Analiza wizualna wykresu prowadzi do jednego, bezdyskusyjnego wniosku – kategoria "Success" (reprezentowana przez największy wycinek) całkowicie i przytłaczająco dominuje nad resztą zmiennych.

Fakt, że sukcesy pokrywają niemal 90% całej powierzchni koła, jest ostatecznym dowodem na niezwykłą niezawodność inżynierii kosmicznej. Całkowite porażki ("Failure") stanowią na wykresie zaledwie wąski margines. Awarie częściowe ("Partial Failure") stanowią mały pasek, a porażki przedstartowe ("Prelaunch Failure") są tak małe, że znikają na wykresie i są niewidoczne gołym okiem.

Wykres ten wprost pokazuje, że z perspektywy statystycznej, loty w kosmos charakteryzują się ogromnym stopniem bezpieczeństwa, a sukces misji jest niemal gwarantowany, szczególnie, że mówimy tutaj o bardzo skomplikowanych systemach oraz sprzętach, które pracują w okropnych warunkach, a mimo to są prawie zawsze zakończone sukcesem.

6. Porównanie względem cechy jakościowej

W celu weryfikacji hipotezy o wpływie komercjalizacji na rynek kosmiczny, przeprowadziłam analizę porównawczą zmiennej ilościowej (Koszt misji) w dwóch grupach.


Na tą potrzebę wyznaczyłam nową zmienną – Erę rynkową.

Zbiór danych podzieliłam na "Erę Historyczną" (misje przed 2010 rokiem) oraz "Erę New Space" (misje od 2010 roku). Podział ten służy sprawdzeniu, czy wejście na rynek nowych, prywatnych firm faktycznie wpłynęło na koszt misji, tak jak wcześniej zaobserwowano oraz czy da się tą granicę "erową" wyraźnie oddzielić.

Statystyki w grupach:

	Era	Liczba_Misji	Srednia_Cena	Mediana_Cena	Min_Cena	Max_Cena	Odchylenie
1	1. Era Historyczna (przed 2010)	425	242.78	69.7	7.0	5000	409.64
2	2. Era New Space (po 2010)	840	70.38	62.0	2.5	450	67.31

Wykres porównawczy:



Wygenerowana tabela statystyk w grupach oraz wykres gęstości pozwalają na wyciągnięcie fascynujących wniosków o transformacji sektora kosmicznego. Różnice między epokami są wręcz drastyczne:

Eksplozja częstotliwości lotów: Pierwszą rzeczą, która rzuca się w oczy w tabeli, jest liczba misji. W znacznie krótszej "Erze New Space" (od 2010 do 2022 roku) odnotowano aż 840 startów, w porównaniu do zaledwie 425 startów z całej długiej "Ery Historycznej". To twardy dowód na to, jak komercjalizacja napędziła i przyspieszyła dostęp do orbity.

Koniec absurdalnie drogich programów: W Erze Historycznej średnia cena misji wynosiła aż 242,78 mln USD i była sztucznie zawyżona przez potężne programy państwowe (co widać po gigantycznej wartości maksymalnej wynoszącej 5000 mln USD).

W epoce New Space zrezygnowano z tak ekstremalnych wydatków – wartość maksymalna to "zaledwie" 450 mln, a średnia rynkowa zjechała do poziomu 70,38 mln USD. Widać również pojawienie się opcji skrajnie budżetowych (najtańsza misja za 2,5 mln USD względem dawnych 7,0 mln USD).

Standaryzacja rynku (spadek odchylenia): Najbardziej imponującą statystyką w tabeli jest odchylenie standardowe. W starych czasach wynosiło ono aż 409,64, co oznaczało totalny rozstrzał i nieprzewidywalność kosztów

(wykres gęstości ma tu bardzo długi, płaski ogon z prawej strony). Obecnie odchylenie spadło drastycznie (do 67,31).

Współczesny rynek kosmiczny stał się wysoce ustandaryzowany, a rozkład cen na wykresie mocno się zwęził i skupił w dwóch "dzwonach" poniżej 100 mln.

Ciekawa Mediana: Co niezwykle ciekawe, koszt typowego, środkowego lotu (mediana) zmienił się w najmniejszym stopniu – spadł z 69,7 mln do 62,0 mln USD.

Oznacza to, że rewolucja "New Space" nie doprowadziła do drastycznego spadku kosztów standardowego lotu. Polegała ona na całkowitej eliminacji skrajności, co pociągnęło w dół średnią i ustabilizowało rynek.

Wniosek końcowy: Analiza w grupach bezsprzecznie udowadnia, że rynek przeszedł transformację – od pojedynczych, nieprzewidywalnych finansowo i ekstremalnie drogich projektów państwowych, do masowych, zoptymalizowanych i silnie ustandaryzowanych usług komercyjnych.

Należy jednak zwrócić uwagę na zestawienie drastycznego spadku średniej i odchylenia standardowego z paradoksalnie stabilną medianą, które prowadzi do ważnego i kluczowego wniosku o naturze tego rynku.

Ekstremalnie drogie, miliardowe programy z Ery Historycznej (odpowiadające za rozciągnięty prawy ogon wykresu) nie były anomalią, lecz stanowiły niezbędną "cegielek" inwestycyjną w rozwój technologii kosmicznych. Były to potężne koszty badawczo-rozwojowe i przecieranie szlaków, w całości finansowane przez budżety państwowe.

Dzisiejsza stabilność i niższe uśrednione koszty w erze New Space wynikają z faktu, że nowoczesne firmy komercyjne budują na fundamentach tamtych historycznych inwestycji.


Mediana udowadnia, że standardowy start rakiety wciąż kosztuje fizycznie podobnie (ok. 60 mln USD), jednak dzięki państwowym inwestycjom z ubiegłego wieku, z dzisiejszego rynku niemal całkowicie zniknęła konieczność ponoszenia tak ekstremalnych kosztów "odkrywania nieznanego".

7. Analiza zależności między zmiennymi

W tym punkcie postanowiłam sprawdzić, czy istnieje zależność między dwiema zmiennymi jakościowymi: Firmą (*Company*) a Statusem misji (*MissionStatus*).

Innymi słowy – sprawdzamy, który z gigantów sektora kosmicznego może pochwalić się największą niezawodnością.

	Failure	Partial Failure	Prelaunch Failure	Success
Arianespace	2.73	1.02	0.00	96.25
CASC	4.14	1.78	0.00	94.08
NASA	5.42	2.96	0.00	91.63
SpaceX	2.75	2.20	0.55	94.51
ULA	0.00	0.66	0.00	99.34



Analiza danych z tabeli pozwala na wyciągnięcie kilku bardzo ciekawych wniosków, które rzucają światło na to, jak różni gracze radzą sobie z bezpieczeństwem lotów:

ULA: United Launch Alliance to absolutny lider bezpieczeństwa w tym zestawieniu. Wynik 99,34% sukcesów i okrągłe 0,00% całkowitych porażek (Failure) to statystyka niemal nieprawdopodobna w tej branży. Wynika to z faktu, że ULA bazuje na niezwykle dopracowanych i sprawdzonych przez

dekady konstrukcjach (jak Atlas V czy Delta IV), co czyni ich najbardziej przewidywalnym dostawcą.

NASA: Choć NASA jest najbardziej prestiżową i znaną agencją, w tabeli ma statystycznie najniższy procent sukcesów (91,63%).

Wynika to prawdopodobnie, nie z braku kompetencji, a z "bagażu historycznego". NASA operuje od lat 50. i w swoich statystykach niesie setki misji z pionierskich czasów, kiedy ryzyko porażki było wpisane w proces nauki. Dodatkowo NASA podejmuje się misji najbardziej ryzykownych i innowacyjnych.

SpaceX: Firma SpaceX jako jedyna w zestawieniu posiada odnotowany status *Prelaunch Failure* (0,55%). Jest to prawdopodobnie ślad słynnej eksplozji na platformie startowej podczas testów (misja AMOS-6). SpaceX ma zbliżony procent sukcesów do chińskiego CASC (ok. 94,5%), co pokazuje, że nowocześni gracze komercyjni bardzo szybko dogonili państwowych gigantów pod względem bezpieczeństwa.

Arianespace: Europejska agencja ze swoim wynikiem 96,25% sukcesów plasuje się w ścisłej czołówce. Świadczy to o bardzo wysokiej kulturze technicznej i rygorystycznych normach bezpieczeństwa, które przekładają się na dużą powtarzalność lotów bez awarii.

Wniosek: Między wyborem agencji a statystyczną szansą na sukces istnieje wyraźna zależność, choć ogólny standard bezpieczeństwa w branży jest imponujący (ponad 90%). Różnice te najłatwiej wytłumaczyć, patrząc na specyfikę i cele danej organizacji. Liderzy niezawodności (jak ULA) stawiają na sprawdzone technologie, podczas gdy niższe wskaźniki u innych (jak NASA) są często "kosztem postępu" i efektem podejmowania się misji o najwyższym stopniu trudności, które przecierają szlaki dla całej reszty branży.

8. Wnioski końcowe

Niniejsza analiza ponad 4000 misji kosmicznych pozwoliła na sformułowanie kompleksowych wniosków dotyczących ewolucji, kosztów i skuteczności podboju kosmosu. Poniżej przedstawiono syntezę najważniejszych wyników:

Typowe wartości: Analiza wykazała, że "standardowy" koszt misji kosmicznej (mediana) oscyluje w granicach 60–70 mln USD. Co ciekawe,

wartość ta jest niezwykle stabilna na przestrzeni dekad, co sugeruje, że bazowy koszt wyniesienia ładunku na orbitę wynika z niezmiennych uwarunkowań technologicznych i fizycznych. W kwestii bezpieczeństwa typowym wynikiem jest sukces, który stanowi ponad 90% wszystkich zarejestrowanych operacji.

Zróźnicowanie danych: Zaobserwowano gigantyczny spadek zróźnicowania kosztów wraz z nadejściem ery "New Space". Podczas gdy w Erze Historycznej odchylenie standardowe wynosiło aż 409,64 mln USD (co świadczy o ogromnej nieprzewidywalności wydatków), obecnie spadło ono do poziomu 67,31 mln USD. Rynek stał się zatem znacznie bardziej ustandaryzowany i policzalny.

Obserwacje odstające: Dane obfitują w interesujące anomalie. Najbardziej spektakularną jest Saturn V (NASA) z kosztem przekraczającym 1160 mln USD, będący symbolem pionierskich nakładów na program księżycowy. Z drugiej strony, nowoczesne firmy jak SpaceX czy CASC generują anomalie w dolnych rejestrach cenowych (misje poniżej 10 mln USD), co wyznacza nowy kierunek rozwoju lekkich i tanich rakiet nośnych.

Różnice między grupami: Analiza porównawcza ujawniła skrajnie różne strategie agencji. ULA to lider niezawodności (ponad 99% sukcesów), stawiający na sprawdzone technologie. NASA cechuje się największym rozrzutem cenowym i "bagażem historycznym", wynikającym z podejmowania najbardziej ryzykownych misji badawczych. Z kolei Arianespace wyróżnia się najbardziej zróźnicowanym portfolio rakiet, dostosowanym do różnych segmentów cenowych.

Zaobserwowane zależności:

- Istnieje słaba ujemna korelacja między rokiem a ceną – technologia z czasem staje się tańsza, choć proces ten jest powolny.
- Istnieje wyraźna zależność między erą rynkową a strukturą kosztów – przejście po 2010 roku w stronę komercjalizacji niemal całkowicie wyeliminowało z rynku misje o ekstremalnie wysokich budżetach.
- Występuje zależność między agencją a skutecznością, gdzie podmioty o najdłuższym stażu (NASA) statystycznie częściej odnotowują historyczne awarie niż nowoczesne, wyspecjalizowane firmy komercyjne.

Podsumowanie końcowe:

Całość analizy prowadzi do wniosku, że sektor kosmiczny przeszedł transformację od fazy drogich, ryzykownych eksperymentów finansowanych przez podatników, do fazy stabilnego, dojrzałego rynku. Wysokie koszty "Ery Historycznej" stanowiły niezbędną inwestycję (cegielekę), która pozwoliła dzisiejszym graczom na bezpieczne i przewidywalne operowanie w przestrzeni kosmicznej przy zachowaniu rygorystycznych standardów.

9. Kod użyty do analizy

Kod użyty do przygotowania danych do statystyki (punkt 3) znajduje się w pliku *przygotowanie_danych.R*.

Gotowy zbiór finalnie został zapisany do pliku *space_missions_clean.csv*.

Kod użyty do generowania statystyk opisowych (punkt 4) znajduje się w pliku *statystyki_opisowe.R*.

Kod użyty do generowania wykresów podstawowych (punkt 5) znajduje się w pliku *wizualizacja_danych.R*.

Wykresy dodatkowe użyte przy pogłębianiu interpretacji wyników z wykresów (punkt) znajdują się w pliku *wizualizacja_dodatek.R*.

Kod użyty do generowania wykresu porównawczego (punkt 6) znajduje się w pliku *wykres_porownawczy.R*.

Kod użyty do analizy zależności znajduje się w pliku *analiza_zaleznosci.R*.